TP 2 — Sujets par groupe

14 groupes · 14 jeux de données · 14 tâches de classification

Chaque groupe applique **la démarche complète du TP2** (version B, ArSarcasm-v2) à son propre jeu de données : audit et prétraitement, Parties A à G, compte-rendu et dépôt Git. Votre fiche donne la tâche, les liens vers les données, les consignes propres à chaque partie et les 12 questions auxquelles votre compte-rendu doit répondre. Pour tout ce qui n'est pas précisé dans votre fiche, suivez le TP2.

RÈGLES COMMUNES

- Respectez le split officiel quand il existe ; sinon, appliquez celui imposé par votre fiche (`random_state=42`).
- Toutes les décisions (prétraitement, architecture, hyperparamètres, nombre d'époques, seuil de décision) se prennent sur **val**. Le test reste scellé jusqu'à la Partie F.
- Toute transformation apprise (vocabulaire, TF-IDF, mise à l'échelle, poids de classes, ré-échantillonnage) est ajustée sur le **train uniquement**.
- Chaque exécution est journalisée dans `results/results.csv` : modèle, prétraitement, graine, métriques val et test, temps d'entraînement, nombre de paramètres entraînés.
- Téléchargez vos données **dès la première séance** : certains accès demandent un compte ou une inscription.

LIVRABLES

- Dépôt Git : `README.md` (commandes d'exécution), `pyproject.toml` + `uv.lock` (ou `requirements.txt` figé), `src/`, `notebooks/`, `tests/`, `results/results.csv`, `predictions/`.
- Prédictions du test de chaque modèle final : `predictions/<modèle>_seed<k>.csv` (id, y_true, y_pred, probabilités).
- Compte-rendu de 6 pages maximum hors annexes, répondant aux questions Q1 à Q12 de votre fiche.

RÉPARTITION

GR.	MEMBRES	FORMAT	SUJET	JEU DE DONNÉES	LANGUE
1	Oumaima	Individuel	Haine et injure en darija	AfriHate (ary)	Darija
2	Elattar & Belmokhtar	Binôme	Haine multi-aspects : attribut ciblé	MLMA (ar → fr)	Arabe, français
3	Bouaouda & Almrani	Binôme	Note d'une critique (1 à 5 étoiles)	LABR	Arabe
4	Gharib	Individuel	Position (stance) envers une cible	Mawqif	Arabe
5	Yahyaoui & Bettar	Binôme	Émotions multi-label (darija, algérien)	BRIGHTER (ary, arq)	Darija, algérien
6	Raoui & El Kaoui	Binôme	Sentiment par aspect (ABSA)	SemEval-2016 ABSA hôtels (ar)	Arabe
7	Ariby & Reda	Binôme	Thèmes multi-label + topic modeling	TweetTopic	Anglais
8	Ait Hafid	Individuel	Catégorisation du sexisme	EDOS	Anglais
9	Sakhi	Individuel	Affirmations à vérifier	CheckThat! 2024 T1 (ar)	Arabe
10	Hamouchi & Bendahmar	Binôme	Techniques de persuasion	ArAIEval 2023 T1	Arabe
11	Jamila & Moutik	Binôme	Valeurs humaines dans les arguments	Touché23-ValueEval	Anglais
12	El Khali	Individuel	Sentiment en darija (arabe + arabizi)	AfriSenti (ary)	Darija
13	Badereddine	Individuel	Actes de langage	ArSAS	Arabe
14	Mouad & Farouk	Binôme	Dialecte arabe (21 pays)	NADI 2021	Arabe dialectal

Groupe 1

Oumaima

Individuel

Darija

Détection de discours haineux et injurieux en darija marocaine

Classer chaque tweet en darija dans l'une de trois classes : **hate** (haine envers un groupe), **abusive** (injurieux sans viser un groupe) ou **neutral**.

DONNÉES

Jeu de données	AfriHate, sous-ensemble *Moroccan Arabic* (ary).
Lien	huggingface.co/datasets/afrihate/afrihate (config `ary`)
Accès	Compte Hugging Face, puis accepter les conditions d'accès sur la page (licence Apache-2.0). À faire dès la première séance.
Taille	3 240 train · 695 dev · 699 test (split officiel).
Colonnes	id, tweet (ou text), label.
Algérien	Le sous-ensemble `arq` du même dataset sert aux Parties E2 et F2.

> **Métriques : macro-F1** sur les 3 classes (principale), F1 de la classe hate, PR-AUC par classe. L'accuracy n'est pas acceptable.

POINTS D'ATTENTION

- La frontière entre haine et simple injure est floue, et la classe hate est rare.
- La darija s'écrit en alphabet arabe ou latin, avec des emprunts au français.

Référence à citer : Muhammad et al., AfriHate, NAACL 2025 — https://arxiv.org/abs/2501.08284

CONSIGNES, PARTIE PAR PARTIE

Protocole	Split officiel train / dev / test ; val = dev. Toutes les décisions se prennent sur val ; le test reste scellé jusqu'à la Partie F. Toute transformation apprise est ajustée sur le train uniquement. Journal `results/results.csv`.
4.1 Audit	Mesurez la part de tweets en écriture latine (arabizi) et en écriture arabe, les emojis, mentions, URL, lettres répétées et mots français. Doublons exacts et après normalisation (dans train, et entre train et test) ; doublons aux labels contradictoires : politique justifiée.
A	Distribution des labels, globalement et par écriture (arabe / latine). Classifieur trivial « classe majoritaire ». Baseline TF-IDF (mots 1–2 + caractères 2–5) + régression logistique `class_weight="balanced"`, seuil(s) choisi(s) sur val. Raccourcis : construisez une courte liste d'insultes fréquentes à partir du train ; règle « contient une insulte de la liste ⇒ abusive ». Taux de chaque classe selon l'écriture.
B	B1 : NLI zero-shot (`MoritzLaurer/mDeBERTa-v3-base-xnli-multilingual-nli-2mil7`) avec trois hypothèses (haine envers un groupe / insulte / contenu neutre) ; au moins 3 formulations (arabe, français, anglais), score seuillé sur val. B2 : `TypicaAI/DarijaToxicityDetector` (DarijaBERT fine-tuné en binaire clean / offensive) + règle « offensive ⇒ abusive ». Lisez sa fiche : sur quelles données a-t-il été entraîné ?
C	Vocabulaire construit sur train (fréquence ≥ 2), taux d'OOV sur val et test ; embeddings aléatoires, AraVec Twitter (figé puis dégelé), fastText entraîné sur votre train. C1 BiLSTM, C2 BiLSTM + attention (implémentée par vous), C3 mini-encodeur Transformer (2 couches, d_model 128, 4 têtes ; ablation sans encodage positionnel), C4 char-CNN. Déséquilibre sur le meilleur modèle : perte pondérée, sur-échantillonnage (train uniquement), seuil optimisé. Le char-CNN (C4) est particulièrement utile ici (arabizi, allongements).
D	D1 : `SI2M-Lab/DarijaBERT` gelé, [CLS] vs moyenne des tokens → régression logistique. D2 : états de tous les tokens → tête BiLSTM + attention de C2 ; visualisez l'attention sur 5 exemples.

E	E1 : `SI2M-Lab/DarijaBERT` et `UBC-NLP/MARBERTv2` fine-tunés ; perte pondérée, seuil choisi sur val. E2 : encodeur partagé, une tête ary et une tête arq (algérien), $L = L_{ary} + \lambda \cdot L_{arq}$, $\lambda \in \{0{,}3 ; 0{,}5 ; 1\}$. Départ : lr 2e-5, batch 32, 3 à 5 époques, warmup 10 %, early stopping sur val, 3 graines.
F	F1 : comparez la distribution des labels de val et de test ; score sur le test avec le seuil choisi sur val, puis F1 = f(seuil) a posteriori (analyse, pas sélection). F2 : dialecte non vu : évaluez le modèle ary sur le test arq, puis réentraînez avec ary + arq. F3 : scores par écriture (arabe / latine) ; réentraînez sans les tweets latins et mesurez l'effet sur eux. F4 : sur les tweets hate et abusive bien détectés, supprimez emojis, ponctuation répétée et insultes de votre liste ; mesurez la chute. F5 : 3 graines, IC à 95 % par bootstrap (1 000), McNemar entre vos deux meilleurs modèles. F6 : 30 erreurs classées (insulte implicite, ironie, cible ambiguë, arabizi mal tokenisé, bruit d'annotation).
G	Tableau final : qualité, robustesse, temps d'entraînement, latence d'inférence par exemple sur CPU, taille du modèle ; matrice de confusion du modèle retenu.

QUESTIONS DU COMPTE-RENDU

Q1. Distribution des labels dans train, val et test, globalement et par écriture (arabe / latine). Scores du classifieur trivial « classe majoritaire ». Quelle métrique retenez-vous, et pourquoi ?

Q2. Raccourcis (Partie A) : quels indices superficiels sont corrélés aux labels ? Que valent vos classifieurs à une seule règle ? Qu'en concluez-vous sur la validité de vos scores ?

Q3. Quels choix de prétraitement avez-vous faits par famille de modèles ? Lesquels détruisent des indices utiles (emojis, lettres répétées, mots français, arabizi) ? Chiffres à l'appui (ablation).

Q4. Zero-shot (B1) : score obtenu et sensibilité à la formulation des hypothèses. Pourquoi un modèle NLI peut-il classer sans exemple d'entraînement ? Quel rôle joue l'attention entre prémisse et hypothèse ?

Q5. Le détecteur DarijaToxicityDetector (B2), entraîné sur une autre plateforme et en binaire, transfère-t-il vers les tweets AfriHate ? Précision et rappel par classe ; d'où vient l'écart ?

Q6. Déséquilibre : comparez pondération de la perte, sur-échantillonnage et optimisation du seuil (tableau). Pourquoi le sur-échantillonnage doit-il être fait après la séparation train / val ?

Q7. C1 vs C2 vs C3 (et C4) : résultats. Les poids d'attention se concentrent-ils sur les insultes, les noms de groupes visés et les emojis ? Effet de l'encodage positionnel ?

Q8. PLM gelé (D) vs fine-tuné (E1) : gain et coût (temps, paramètres entraînés). SI2M-Lab/DarijaBERT vs UBC-NLP/MARBERTv2 : lequel, et pourquoi ?

Q9. Multi-tâche (E2) : l'ajout de l'algérien améliore-t-il la tâche principale ? Effet de λ. Pourquoi une tâche auxiliaire peut-elle aider… ou nuire ?

Q10. Décalage de prior (F1) : comparez la distribution des labels de val et de test. Écart entre le seuil (ou la règle de décision) choisi sur val et l'optimum a posteriori sur le test. Que mettriez-vous en place en production (recalibration, monitoring) ?

Q11. Dialecte non vu (F2) : chute mesurée sur l'algérien, et écart entre écriture arabe et latine. Comment évalueriez-vous honnêtement ce modèle avant de le déployer sur des commentaires marocains ?

Q12. Analyse d'erreurs (F6) : catégories dominantes, part du bruit d'annotation. Quel modèle mettriez-vous en production, et pourquoi (qualité, robustesse, coût, latence — chiffres à l'appui) ?

Pour tout ce qui n'est pas précisé ici (code de départ, classe MultiTask, format du compte-rendu), suivez le TP2.

Groupe 2

Elattar & Belmokhtar

Binôme

Arabe, français

Discours haineux multi-aspects : quel attribut est visé ? (arabe → français)

Tâche principale : prédire l'**attribut ciblé** d'un tweet arabe hostile (origine, genre, religion, autre). Aspects auxiliaires : type d'hostilité (multi-label), direct / indirect, groupe ciblé, sentiment de l'annotateur.

DONNÉES

Jeu de données	MLMA hate speech (Ousidhoum et al., EMNLP 2019) — arabe, français, anglais.
Lien	github.com/HKUST-KnowComp/MLMA_hate_speech → `hate_speech_mlma.zip`
Fichiers	`ar_dataset.csv` (3 353) · `fr_dataset.csv` (4 014) · `en_dataset.csv` (5 647). Colonnes : tweet, sentiment (type d'hostilité, labels combinés « a_b »), directness, annotator_sentiment, target, group.
Mots-clés	`keywords.txt` dans le dépôt : les mots-clés utilisés pour collecter les tweets.

> **Métriques : macro-F1** sur l'attribut ciblé (principale) ; micro- et macro-F1 pour le type d'hostilité.

POINTS D'ATTENTION

- Très peu de données et labels bruités (votes de plusieurs annotateurs fusionnés).
- Le transfert arabe → français est un changement de langue et de contexte.

Référence à citer : Ousidhoum et al., Multilingual and Multi-Aspect Hate Speech Analysis, EMNLP 2019 — https://arxiv.org/abs/1908.11049

CONSIGNES, PARTIE PAR PARTIE

Protocole	Pas de split officiel : 80 / 10 / 10 stratifié sur l'attribut ciblé (`random_state=42`), pour chaque langue. Toutes les décisions se prennent sur val ; le test reste scellé jusqu'à la Partie F. Toute transformation apprise est ajustée sur le train uniquement. Journal `results/results.csv`.
4.1 Audit	Décodez les labels combinés (« abusive_hateful » → 2 labels) ; @user, URL, emojis ; doublons ; classes à un seul exemple à fusionner avec « other » (justifiez). Doublons exacts et après normalisation (dans train, et entre train et test) ; doublons aux labels contradictoires : politique justifiée.
A	Distribution des labels, globalement et par langue (arabe / français) et direct / indirect. Classifieur trivial « toujours other ». Baseline TF-IDF (mots 1–2 + caractères 2–5) + régression logistique `class_weight="balanced"`, seuil(s) choisi(s) sur val. Raccourcis : règle « contient un mot-clé de collecte (`keywords.txt`) ⇒ attribut associé ».
B	B1 : NLI zero-shot (`MoritzLaurer/mDeBERTa-v3-base-xnli-multilingual-nli-2mil7`) avec une hypothèse par attribut (origine, genre, religion…) en arabe et en français ; au moins 3 formulations (arabe, français, anglais), score seuillé sur val. B2 : transfert inter-langue : fine-tunez `xlm-roberta-base` sur `en_dataset.csv` (anglais) et appliquez-le à l'arabe sans aucun exemple arabe.
C	Vocabulaire construit sur train (fréquence ≥ 2), taux d'OOV sur val et test ; embeddings aléatoires, AraVec (arabe), fastText `cc.fr.300` (français). C1 BiLSTM, C2 BiLSTM + attention (implémentée par vous), C3 mini-encodeur Transformer (2 couches, d_model 128, 4 têtes ; ablation sans encodage positionnel), C4 char-CNN. Déséquilibre sur le meilleur modèle : perte pondérée, sur-échantillonnage (train uniquement), seuil optimisé.
D	D1 : `UBC-NLP/MARBERTv2` gelé, [CLS] vs moyenne des tokens → régression logistique. D2 : états de tous les tokens → tête BiLSTM + attention de C2 ; visualisez l'attention sur 5 exemples.
E	E1 : `UBC-NLP/MARBERTv2` et `aubmindlab/bert-base-arabertv02-twitter` ; `xlm-roberta-base` pour F2 fine-tunés ; perte pondérée, seuil choisi sur val. E2 : multi-tâche sur les 5 aspects (attribut, hostilité, direct, groupe, sentiment de l'annotateur) ; comparez mono- et multi-tâche. Départ : lr 2e-5, batch 32, 3 à 5 époques, warmup 10 %, early stopping sur val, 3 graines.

F	F1 : comparez la distribution des labels de val et de test ; score sur le test avec le seuil choisi sur val, puis F1 = f(seuil) a posteriori (analyse, pas sélection). F2 : langue non vue : entraînez sur l'arabe, testez sur le français en zero-shot (`xlm-roberta-base`), puis entraînez sur arabe + français. F3 : scores avec / sans mot-clé de collecte dans le tweet. F4 : supprimez les mots-clés de collecte des tweets bien classés ; mesurez la chute. F5 : 3 graines, IC à 95 % par bootstrap (1 000), McNemar entre vos deux meilleurs modèles. F6 : 30 erreurs classées (cible implicite, plusieurs cibles, ironie, attribut voisin, bruit d'annotation).
G	Tableau final : qualité, robustesse, temps d'entraînement, latence d'inférence par exemple sur CPU, taille du modèle ; matrice de confusion du modèle retenu.

QUESTIONS DU COMPTE-RENDU

Q1. Distribution des labels dans train, val et test, globalement et par langue (arabe / français) et direct / indirect. Scores du classifieur trivial « toujours other ». Quelle métrique retenez-vous, et pourquoi ?

Q2. Raccourcis (Partie A) : quels indices superficiels sont corrélés aux labels ? Que valent vos classifieurs à une seule règle ? Qu'en concluez-vous sur la validité de vos scores ?

Q3. Quels choix de prétraitement avez-vous faits par famille de modèles ? Lesquels détruisent des indices utiles (emojis, mentions, mots-clés, diacritiques) ? Chiffres à l'appui (ablation).

Q4. Zero-shot (B1) : score obtenu et sensibilité à la formulation des hypothèses. Pourquoi un modèle NLI peut-il classer sans exemple d'entraînement ? Quel rôle joue l'attention entre prémisse et hypothèse ?

Q5. Transfert anglais → arabe (B2) : scores et erreurs typiques. Que vaut la règle « mot-clé de collecte ⇒ attribut » ? Qu'en concluez-vous sur la validité du dataset ?

Q6. Déséquilibre : comparez pondération de la perte, sur-échantillonnage et optimisation du seuil (tableau). Pourquoi le sur-échantillonnage doit-il être fait après la séparation train / val ?

Q7. C1 vs C2 vs C3 (et C4) : résultats. Les poids d'attention se concentrent-ils sur les noms de groupes et les mots-clés de collecte ? Effet de l'encodage positionnel ?

Q8. PLM gelé (D) vs fine-tuné (E1) : gain et coût (temps, paramètres entraînés). UBC-NLP/MARBERTv2 vs aubmindlab/bert-base-arabertv02-twitter : lequel, et pourquoi ?

Q9. Multi-tâche (E2) : l'apprentissage conjoint des 5 aspects améliore-t-il la tâche principale ? Effet de λ. Pourquoi une tâche auxiliaire peut-elle aider… ou nuire ?

Q10. Décalage de prior (F1) : comparez la distribution des labels de val et de test. Écart entre le seuil (ou la règle de décision) choisi sur val et l'optimum a posteriori sur le test. Que mettriez-vous en place en production (recalibration, monitoring) ?

Q11. Langue non vue (F2) : chute arabe → français et erreurs typiques. L'ajout du français à l'entraînement aide-t-il l'arabe ?

Q12. Analyse d'erreurs (F6) : catégories dominantes, part du bruit d'annotation. Quel modèle mettriez-vous en production, et pourquoi (qualité, robustesse, coût, latence — chiffres à l'appui) ?

Pour tout ce qui n'est pas précisé ici (code de départ, classe MultiTask, format du compte-rendu), suivez le TP2.

Groupe 3

Bouaouda & Almrani

Binôme

Arabe

Prédire la note d'une critique de livre (1 à 5 étoiles)

Prédire la note donnée par le lecteur (**1 à 5 étoiles**) à partir du texte arabe de sa critique. C'est une classification ordinale : se tromper de 4 à 5 est moins grave que de 1 à 5.

DONNÉES

Jeu de données	LABR — Large-scale Arabic Book Reviews (Aly et Atiya, ACL 2013), critiques GoodReads.
Lien	github.com/mohamedadaly/LABR, dossier `data/`
Fichiers	`reviews.tsv` (63 257 critiques : note, id critique, id utilisateur, id livre, texte). Split officiel 5 classes : `5class-unbalanced-train.txt` (50 606 ids) et `5class-unbalanced-test.txt` (12 651 ids).
Lecteur	`python/labr.py` du dépôt montre comment relier ids et critiques.

> **Métriques : macro-F1** (principale), **MAE** sur les étoiles, F1 pondéré.

POINTS D'ATTENTION

- 4★ et 5★ se ressemblent beaucoup ; 1★ et 2★ sont rares.
- Chaque lecteur a sa propre échelle de notation ; les critiques sont plus longues que des tweets.

Référence à citer : Aly et Atiya, LABR — https://arxiv.org/abs/1411.6718

CONSIGNES, PARTIE PAR PARTIE

Protocole	Ids officiels du split 5 classes déséquilibré ; val = 10 % stratifié du train. Toutes les décisions se prennent sur val ; le test reste scellé jusqu'à la Partie F. Toute transformation apprise est ajustée sur le train uniquement. Journal `results/results.csv`.
4.1 Audit	Longueur des critiques, critiques vides ou très courtes, doublons (même texte pour plusieurs livres), mots non arabes, diacritiques, tatweel. Doublons exacts et après normalisation (dans train, et entre train et test) ; doublons aux labels contradictoires : politique justifiée.
A	Distribution des labels, globalement et par note et tranche de longueur. Classifieur trivial « toujours 5★ ». Baseline TF-IDF (mots 1–2 + caractères 2–5) + régression logistique `class_weight="balanced"`, seuil(s) choisi(s) sur val. Raccourcis : corrélation longueur ↔ note ; règle « critique très courte ⇒ 5★ » ; note moyenne de l'utilisateur dans le train comme prédicteur.
B	B1 : NLI zero-shot (`MoritzLaurer/mDeBERTa-v3-base-xnli-multilingual-nli-2mil7`) avec « Le lecteur a adoré ce livre », « Le lecteur a trouvé ce livre moyen », « Le lecteur a détesté ce livre » ; au moins 3 formulations (arabe, français, anglais), score seuillé sur val. B2 : `CAMeL-Lab/bert-base-arabic-camelbert-da-sentiment` : convertissez P(positif) − P(négatif) en étoiles par des seuils choisis sur val.
C	Vocabulaire construit sur train (fréquence ≥ 2), taux d'OOV sur val et test ; embeddings aléatoires, AraVec (figé puis dégelé). C1 BiLSTM, C2 BiLSTM + attention (implémentée par vous), C3 mini-encodeur Transformer (2 couches, d_model 128, 4 têtes ; ablation sans encodage positionnel), C4 char-CNN. Déséquilibre sur le meilleur modèle : perte pondérée, sur-échantillonnage (train uniquement), seuil optimisé. Budget : un sous-échantillon stratifié du train est autorisé pour la Partie C ; max_len 256 partout.
D	D1 : `aubmindlab/bert-base-arabertv02` gelé, [CLS] vs moyenne des tokens → régression logistique. D2 : états de tous les tokens → tête BiLSTM + attention de C2 ; visualisez l'attention sur 5 exemples.
E	E1 : `aubmindlab/bert-base-arabertv02` et `UBC-NLP/MARBERTv2` fine-tunés ; perte pondérée, seuil choisi sur val. E2 : tête classification (5 classes) + tête régression (MSE sur la note), λ choisi sur val ; comparez F1 et MAE. Départ : lr 2e-5, batch 32, 3 à 5 époques, warmup 10 %, early stopping sur val, 3 graines.

F	F1 : comparez la distribution des labels de val et de test ; score sur le test avec le seuil choisi sur val, puis F1 = f(seuil) a posteriori (analyse, pas sélection). F2 : livres non vus : split par id de livre (`GroupShuffleSplit`), puis utilisateurs non vus. F3 : scores par tranche de longueur ; comparez à la règle « note moyenne de l'utilisateur ». F4 : supprimez les mots d'opinion forts (رائع, ممل…) des critiques bien classées ; mesurez la chute. F5 : 3 graines, IC à 95 % par bootstrap (1 000), McNemar entre vos deux meilleurs modèles. F6 : 30 erreurs classées (4★ vs 5★, critique ironique, critique de l'édition et non du livre, texte tronqué, note incohérente avec le texte).
G	Tableau final : qualité, robustesse, temps d'entraînement, latence d'inférence par exemple sur CPU, taille du modèle ; matrice de confusion du modèle retenu.

QUESTIONS DU COMPTE-RENDU

Q1. Distribution des labels dans train, val et test, globalement et par note et tranche de longueur. Scores du classifieur trivial « toujours 5★ ». Quelle métrique retenez-vous, et pourquoi ?

Q2. Raccourcis (Partie A) : quels indices superficiels sont corrélés aux labels ? Que valent vos classifieurs à une seule règle ? Qu'en concluez-vous sur la validité de vos scores ?

Q3. Quels choix de prétraitement avez-vous faits par famille de modèles ? Lesquels détruisent des indices utiles (ponctuation, emojis, longueur, mots d'intensité) ? Chiffres à l'appui (ablation).

Q4. Zero-shot (B1) : score obtenu et sensibilité à la formulation des hypothèses. Pourquoi un modèle NLI peut-il classer sans exemple d'entraînement ? Quel rôle joue l'attention entre prémisse et hypothèse ?

Q5. Transfert sans entraînement (B2) : précision, rappel, F1. Que révèle-t-il de la tâche ? Son score est-il exempt de contamination ?

Q6. Déséquilibre et ordinalité : macro-F1 ou MAE, laquelle choisir pour un site de recommandation, et pourquoi ? Comparez pondération, sur-échantillonnage et tête de régression (tableau).

Q7. C1 vs C2 vs C3 (et C4) : résultats. Les poids d'attention se concentrent-ils sur les mots d'opinion et de nuance (لكن) ? Effet de l'encodage positionnel ?

Q8. PLM gelé (D) vs fine-tuné (E1) : gain et coût (temps, paramètres entraînés). aubmindlab/bert-base-arabertv02 vs UBC-NLP/MARBERTv2 : lequel, et pourquoi ?

Q9. Multi-tâche (E2) : la tête de régression améliore-t-il la tâche principale ? Effet de λ. Pourquoi une tâche auxiliaire peut-elle aider… ou nuire ?

Q10. Décalage de prior (F1) : comparez la distribution des labels de val et de test. Écart entre le seuil (ou la règle de décision) choisi sur val et l'optimum a posteriori sur le test. Que mettriez-vous en place en production (recalibration, monitoring) ?

Q11. Livres et utilisateurs non vus (F2) : chute mesurée. Le modèle apprend-il le livre plutôt que l'opinion ?

Q12. Analyse d'erreurs (F6) : catégories dominantes, part du bruit d'annotation. Quel modèle mettriez-vous en production, et pourquoi (qualité, robustesse, coût, latence — chiffres à l'appui) ?

Pour tout ce qui n'est pas précisé ici (code de départ, classe MultiTask, format du compte-rendu), suivez le TP2.

Groupe 4

Gharib

Individuel

Arabe

Détection de position (stance) envers une cible en arabe

Pour un tweet arabe et une **cible** donnée (vaccin COVID, transformation numérique, autonomisation des femmes), prédire la position de l'auteur : **Favor**, **Against** ou **None**.

DONNÉES

Jeu de données	Mawqif (Alturayeif et al.), utilisé par la tâche partagée StanceEval 2024.
Lien	github.com/NoraAlt/Mawqif-Arabic-Stance, dossier `Data/`
Fichiers	`Mawqif_AllTargets_Train.csv` (3 502 tweets) et `Mawqif_AllTargets_Test.csv` (619 tweets, labels inclus). N'utilisez pas le fichier *Blind Test* (sans labels).
Colonnes	text, target, stance (+ confiance), sentiment, sarcasm, raisons de la position, date.

> **Métriques : F1 moyen des classes Favor et Against** (métrique de StanceEval, principale) et macro-F1 sur les 3 classes.

POINTS D'ATTENTION

- La position dépend de la cible : le même tweet peut être Favor pour une cible et None pour une autre.
- Sentiment et position sont deux choses différentes.

Référence à citer : Dépôt Mawqif (références dans le README) — https://github.com/NoraAlt/Mawqif-Arabic-Stance

CONSIGNES, PARTIE PAR PARTIE

Protocole	Train et Test fournis ; val = 10 % du train, stratifié par cible × position. Toutes les décisions se prennent sur val ; le test reste scellé jusqu'à la Partie F. Toute transformation apprise est ajustée sur le train uniquement. Journal `results/results.csv`.
4.1 Audit	Inspectez la colonne stance : toutes les lignes ont-elles une valeur ? Au moins un artefact de lecture du CSV vous attend : identifiez-le et corrigez-le. Comptez URL, mentions, hashtags et emojis par cible. Doublons exacts et après normalisation (dans train, et entre train et test) ; doublons aux labels contradictoires : politique justifiée.
A	Distribution des labels, globalement et par cible. Classifieur trivial « toujours Favor ». Baseline TF-IDF (mots 1–2 + caractères 2–5) + régression logistique `class_weight="balanced"`, seuil(s) choisi(s) sur val. Raccourcis : règle « cible ⇒ position majoritaire de cette cible » ; règle « contient un hashtag de soutien ⇒ Favor ».
B	B1 : NLI zero-shot (`MoritzLaurer/mDeBERTa-v3-base-xnli-multilingual-nli-2mil7`) avec des hypothèses dépendantes de la cible (« L'auteur soutient le vaccin contre la COVID », « L'auteur s'y oppose ») ; au moins 3 formulations (arabe, français, anglais), score seuillé sur val. B2 : `CAMeL-Lab/bert-base-arabic-camelbert-da-sentiment` + règle « positif ⇒ Favor, négatif ⇒ Against, neutre ⇒ None » ; comparez aussi avec la colonne sentiment fournie.
C	Vocabulaire construit sur train (fréquence ≥ 2), taux d'OOV sur val et test ; embeddings aléatoires, AraVec Twitter (figé puis dégelé). C1 BiLSTM, C2 BiLSTM + attention (implémentée par vous), C3 mini-encodeur Transformer (2 couches, d_model 128, 4 têtes ; ablation sans encodage positionnel), C4 char-CNN. Déséquilibre sur le meilleur modèle : perte pondérée, sur-échantillonnage (train uniquement), seuil optimisé. Entrée : cible concaténée au tweet ; option : attention conditionnée par la cible.
D	D1 : `aubmindlab/bert-base-arabertv02-twitter` gelé, [CLS] vs moyenne des tokens → régression logistique. D2 : états de tous les tokens → tête BiLSTM + attention de C2 ; visualisez l'attention sur 5 exemples.
E	E1 : `aubmindlab/bert-base-arabertv02-twitter` et `UBC-NLP/MARBERTv2` fine-tunés, entrée en paire (cible [SEP] tweet) ; perte pondérée, seuil choisi sur val. E2 : position + sentiment (colonne sentiment), puis 3e tête sarcasme. Départ : lr 2e-5, batch 32, 3 à 5 époques, warmup 10 %, early stopping sur val, 3 graines.

F	F1 : comparez la distribution des labels de val et de test ; score sur le test avec le seuil choisi sur val, puis F1 = f(seuil) a posteriori (analyse, pas sélection). F2 : cible non vue : entraînez sur 2 cibles, testez sur la 3e (3 permutations). F3 : appliquez la règle « cible ⇒ position » au test ; scores par cible. F4 : supprimez la mention explicite de la cible (mots-clés, hashtags) dans les tweets bien classés ; mesurez la chute. F5 : 3 graines, IC à 95 % par bootstrap (1 000), McNemar entre vos deux meilleurs modèles. F6 : 30 erreurs classées (position implicite, ironie ou sarcasme, sentiment opposé à la position, cible mal identifiée, bruit d'annotation).
G	Tableau final : qualité, robustesse, temps d'entraînement, latence d'inférence par exemple sur CPU, taille du modèle ; matrice de confusion du modèle retenu.

QUESTIONS DU COMPTE-RENDU

Q1. Distribution des labels dans train, val et test, globalement et par cible. Scores du classifieur trivial « toujours Favor ». Quelle métrique retenez-vous, et pourquoi ?

Q2. Raccourcis (Partie A) : quels indices superficiels sont corrélés aux labels ? Que valent vos classifieurs à une seule règle ? Qu'en concluez-vous sur la validité de vos scores ?

Q3. Quels choix de prétraitement avez-vous faits par famille de modèles ? Lesquels détruisent des indices utiles (hashtags, emojis, négations) ? Chiffres à l'appui (ablation).

Q4. Zero-shot (B1) : score obtenu et sensibilité à la formulation des hypothèses. Pourquoi un modèle NLI peut-il classer sans exemple d'entraînement ? Quel rôle joue l'attention entre prémisse et hypothèse ?

Q5. Règle « sentiment ⇒ position » (B2) : précision, rappel, F1. Donnez trois tweets négatifs pourtant Favor. Que révèle la relation entre sentiment et position dans ce corpus ?

Q6. Déséquilibre : comparez pondération de la perte, sur-échantillonnage et optimisation du seuil (tableau). Pourquoi le sur-échantillonnage doit-il être fait après la séparation train / val ?

Q7. C1 vs C2 vs C3 (et C4) : résultats. Les poids d'attention se concentrent-ils sur les mots de la cible et les marqueurs de soutien ou de rejet ? Effet de l'encodage positionnel ?

Q8. PLM gelé (D) vs fine-tuné (E1) : gain et coût (temps, paramètres entraînés). aubmindlab/bert-base-arabertv02-twitter vs UBC-NLP/MARBERTv2 : lequel, et pourquoi ?

Q9. Multi-tâche (E2) : l'ajout du sentiment (puis du sarcasme) améliore-t-il la tâche principale ? Effet de λ. Pourquoi une tâche auxiliaire peut-elle aider… ou nuire ?

Q10. Décalage de prior (F1) : comparez la distribution des labels de val et de test. Écart entre le seuil (ou la règle de décision) choisi sur val et l'optimum a posteriori sur le test. Que mettriez-vous en place en production (recalibration, monitoring) ?

Q11. Cible non vue (F2) : chute pour chacune des 3 permutations. Que faudrait-il pour ajouter une nouvelle cible en production ?

Q12. Analyse d'erreurs (F6) : catégories dominantes, part du bruit d'annotation. Quel modèle mettriez-vous en production, et pourquoi (qualité, robustesse, coût, latence — chiffres à l'appui) ?

Pour tout ce qui n'est pas précisé ici (code de départ, classe MultiTask, format du compte-rendu), suivez le TP2.

Groupe 5

Yahyaoui & Bettar

Binôme

Darija, algérien

Détection multi-label d'émotions en darija et en arabe algérien

Pour chaque texte, prédire l'ensemble des émotions présentes parmi **joie, tristesse, peur, colère, surprise, dégoût** (zéro, une ou plusieurs). Pour l'algérien, une piste donne aussi l'intensité de chaque émotion (0 à 3).

DONNÉES

Jeu de données	BRIGHTER — SemEval-2025 Tâche 11, langues Moroccan Arabic (ary) et Algerian Arabic (arq).
Liens	brighter-dataset.github.io (téléchargement) · github.com/emotion-analysis-project/SemEval2025-Task11 (votes individuels arq)
Taille	ary : 1 608 train · 267 dev · 812 test. arq : 901 train · 100 dev · 902 test.
Pistes	A : présence des émotions (ary et arq). B : intensité (arq uniquement).
À vérifier	Que les labels du test sont présents dans votre téléchargement ; sinon, dev devient le test scellé et val = 10 % du train.

> **Métriques : macro-F1** sur les 6 émotions (principale) ; Pearson r pour l'intensité (arq).

POINTS D'ATTENTION

- Multi-label : un seuil par émotion ; beaucoup de textes n'ont qu'une émotion ou aucune.
- Très peu de données d'entraînement, surtout en algérien.

Référence à citer : Muhammad et al., BRIGHTER, 2025 — https://arxiv.org/abs/2502.11926

CONSIGNES, PARTIE PAR PARTIE

Protocole	train / dev / test de chaque langue ; val = dev. Toutes les décisions se prennent sur val ; le test reste scellé jusqu'à la Partie F. Toute transformation apprise est ajustée sur le train uniquement. Journal `results/results.csv`.
4.1 Audit	Écriture (arabe / latine), emojis, rires, mots français ; nombre d'émotions par texte. Doublons exacts et après normalisation (dans train, et entre train et test) ; doublons aux labels contradictoires : politique justifiée.
A	Distribution des labels, globalement et par langue (ary / arq) et nombre d'émotions par texte. Classifieur trivial « aucune émotion » et « toujours l'émotion la plus fréquente ». Baseline TF-IDF (mots 1–2 + caractères 2–5) + régression logistique one-vs-rest, seuil(s) choisi(s) sur val. Raccourcis : règles « emoji de rire ⇒ joie » et « emoji de pleurs ⇒ tristesse ».
B	B1 : NLI zero-shot (`MoritzLaurer/mDeBERTa-v3-base-xnli-multilingual-nli-2mil7`) avec une hypothèse par émotion (« L'auteur exprime de la colère »…), décision indépendante par émotion ; au moins 3 formulations (arabe, français, anglais), score seuillé sur val. B2 : `CAMeL-Lab/bert-base-arabic-camelbert-da-sentiment` + règles (positif ⇒ joie ; négatif ⇒ colère et tristesse).
C	Vocabulaire construit sur train (fréquence ≥ 2), taux d'OOV sur val et test ; embeddings aléatoires, AraVec Twitter, fastText entraîné sur votre train. C1 BiLSTM, C2 BiLSTM + attention (implémentée par vous), C3 mini-encodeur Transformer (2 couches, d_model 128, 4 têtes ; ablation sans encodage positionnel), C4 char-CNN. Déséquilibre sur le meilleur modèle : perte pondérée, sur-échantillonnage (train uniquement), seuil optimisé. Sortie : 6 sigmoïdes + BCE, seuil par émotion choisi sur val. Le char-CNN (C4) est particulièrement utile ici.
D	D1 : `SI2M-Lab/DarijaBERT` gelé, [CLS] vs moyenne des tokens → régression logistique. D2 : états de tous les tokens → tête BiLSTM + attention de C2 ; visualisez l'attention sur 5 exemples.
E	E1 : `SI2M-Lab/DarijaBERT` et `UBC-NLP/MARBERTv2` fine-tunés ; perte pondérée, seuil choisi sur val. E2 : arq : tête présence (6 sigmoïdes) + tête intensité ; option : têtes ary et arq séparées sur un encodeur partagé. Départ : lr 2e-5, batch 32, 3 à 5 époques, warmup 10 %, early stopping sur val, 3 graines.

F	F1 : fréquence de chaque émotion dans val et test ; F1 par émotion avec les seuils de val. F2 : dialecte non vu : entraînez sur arq, testez sur ary, et inversement. F3 : scores avec / sans emojis. F4 : supprimez emojis et rires des textes bien classés ; mesurez la chute. F5 : 3 graines, IC à 95 % par bootstrap (1 000), McNemar entre vos deux meilleurs modèles. F6 : 30 erreurs classées (émotion implicite, plusieurs émotions, ironie, dialecte, bruit d'annotation).
G	Tableau final : qualité, robustesse, temps d'entraînement, latence d'inférence par exemple sur CPU, taille du modèle ; matrice de confusion du modèle retenu.

QUESTIONS DU COMPTE-RENDU

Q1. Distribution des labels dans train, val et test, globalement et par langue (ary / arq) et nombre d'émotions par texte. Scores du classifieur trivial « aucune émotion » et « toujours l'émotion la plus fréquente ». Quelle métrique retenez-vous, et pourquoi ?

Q2. Raccourcis (Partie A) : quels indices superficiels sont corrélés aux labels ? Que valent vos classifieurs à une seule règle ? Qu'en concluez-vous sur la validité de vos scores ?

Q3. Quels choix de prétraitement avez-vous faits par famille de modèles ? Lesquels détruisent des indices utiles (emojis, rires, lettres répétées, arabizi) ? Chiffres à l'appui (ablation).

Q4. Zero-shot (B1) : score obtenu et sensibilité à la formulation des hypothèses. Pourquoi un modèle NLI peut-il classer sans exemple d'entraînement ? Quel rôle joue l'attention entre prémisse et hypothèse ?

Q5. Transfert sans entraînement (B2) : précision, rappel, F1. Que révèle-t-il de la tâche ? Son score est-il exempt de contamination ?

Q6. Multi-label : seuil unique vs seuil par label, pondération des positifs (tableau). Quels labels restent à F1 faible, et combien d'exemples d'entraînement avaient-ils ?

Q7. C1 vs C2 vs C3 (et C4) : résultats. Les poids d'attention se concentrent-ils sur les emojis, les interjections et les mots d'émotion ? Effet de l'encodage positionnel ?

Q8. PLM gelé (D) vs fine-tuné (E1) : gain et coût (temps, paramètres entraînés). SI2M-Lab/DarijaBERT vs UBC-NLP/MARBERTv2 : lequel, et pourquoi ?

Q9. Multi-tâche (E2) : la tête d'intensité (ou la langue voisine) améliore-t-il la tâche principale ? Effet de λ. Pourquoi une tâche auxiliaire peut-elle aider… ou nuire ?

Q10. Décalage de prior (F1) : comparez la distribution des labels de val et de test. Écart entre le seuil (ou la règle de décision) choisi sur val et l'optimum a posteriori sur le test. Que mettriez-vous en place en production (recalibration, monitoring) ?

Q11. Dialecte non vu (F2) : quelles émotions résistent au transfert algérien → marocain, lesquelles s'effondrent ?

Q12. Analyse d'erreurs (F6) : catégories dominantes, part du bruit d'annotation. Quel modèle mettriez-vous en production, et pourquoi (qualité, robustesse, coût, latence — chiffres à l'appui) ?

Pour tout ce qui n'est pas précisé ici (code de départ, classe MultiTask, format du compte-rendu), suivez le TP2.

Groupe 6

Raoui & El Kaoui

Binôme

Arabe

Analyse de sentiment par aspect sur des avis d'hôtels en arabe

(1) **Détection des catégories d'aspect** : pour chaque phrase, trouver les catégories abordées parmi 34 paires ENTITÉ#ATTRIBUT (ex. SERVICE#GENERAL, ROOMS#CLEANLINESS), en multi-label. (2) **Polarité** de chaque aspect : positive, negative ou neutral.

DONNÉES

Jeu de données	SemEval-2016 Tâche 5, avis d'hôtels en arabe (Al-Smadi et al.).
Lien	github.com/msmadi/ABSA-Hotels → `SemEval2016_arabic.zip` (licence MIT)
Fichiers	`AR_Hotels_Train_SB1.xml` : 1 839 avis, 4 802 phrases. `AR_HOTE_SB1_TEST.xml.gold` : 452 avis, 1 227 phrases. Chaque phrase porte ses opinions (category, polarity).

> **Métriques : micro-F1** pour la détection des catégories (métrique officielle) ; **macro-F1** et accuracy pour la polarité.

POINTS D'ATTENTION

- 34 catégories avec une longue traîne, plusieurs aspects par phrase.
- Une même phrase peut contenir un aspect positif et un aspect négatif ; la classe neutral est rare.

Référence à citer : Dépôt ABSA-Hotels (références dans le README) — https://github.com/msmadi/ABSA-Hotels

CONSIGNES, PARTIE PAR PARTIE

Protocole	Fichiers train et test gold (niveau phrase, SB1) ; val = 10 % des **avis** du train (split par avis, pas par phrase). Toutes les décisions se prennent sur val ; le test reste scellé jusqu'à la Partie F. Toute transformation apprise est ajustée sur le train uniquement. Journal `results/results.csv`.
4.1 Audit	Parsing XML ; phrases dupliquées ; phrases sans opinion ; nombre d'aspects par phrase ; diacritiques et dialecte. Doublons exacts et après normalisation (dans train, et entre train et test) ; doublons aux labels contradictoires : politique justifiée.
A	Distribution des labels, globalement et par entité (HOTEL, ROOMS, SERVICE…) et nombre d'aspects par phrase. Classifieur trivial « toujours SERVICE#GENERAL, positive ». Baseline TF-IDF (mots 1–2 + caractères 2–5) + régression logistique one-vs-rest, seuil(s) choisi(s) sur val. Raccourcis : règle « mot-clé ⇒ catégorie » (ex. غرفة ⇒ ROOMS) ; règle « polarité de la phrase ⇒ polarité de chaque aspect ».
B	B1 : NLI zero-shot (`MoritzLaurer/mDeBERTa-v3-base-xnli-multilingual-nli-2mil7`) avec « Cette phrase parle du service de l'hôtel » pour chaque catégorie, puis « L'avis sur le service est positif » ; au moins 3 formulations (arabe, français, anglais), score seuillé sur val. B2 : sentiment de phrase (`CAMeL-Lab/bert-base-arabic-camelbert-da-sentiment`) copié sur tous les aspects de la phrase.
C	Vocabulaire construit sur train (fréquence ≥ 2), taux d'OOV sur val et test ; embeddings aléatoires, AraVec (figé puis dégelé). C1 BiLSTM, C2 BiLSTM + attention (implémentée par vous), C3 mini-encodeur Transformer (2 couches, d_model 128, 4 têtes ; ablation sans encodage positionnel), C4 char-CNN. Déséquilibre sur le meilleur modèle : perte pondérée, sur-échantillonnage (train uniquement), seuil optimisé. Catégories : 34 sigmoïdes, seuil par catégorie. Polarité : BiLSTM + attention conditionnée par l'aspect.
D	D1 : `aubmindlab/bert-base-arabertv02` gelé, [CLS] vs moyenne des tokens → régression logistique. D2 : états de tous les tokens → tête BiLSTM + attention de C2 ; visualisez l'attention sur 5 exemples.
E	E1 : `aubmindlab/bert-base-arabertv02` et `CAMeL-Lab/bert-base-arabic-camelbert-msa` fine-tunés ; polarité en paire (phrase [SEP] nom de la catégorie) ; perte pondérée, seuil choisi sur val. E2 : encodeur partagé : tête catégories (34 sigmoïdes) + tête polarité ; comparez au pipeline en deux modèles. Départ : lr 2e-5, batch 32, 3 à 5 époques, warmup 10 %, early stopping sur val, 3 graines.

F	F1 : comparez la distribution des labels de val et de test ; score sur le test avec le seuil choisi sur val, puis F1 = f(seuil) a posteriori (analyse, pas sélection). F2 : entité non vue : retirez FOOD_DRINKS du train, testez sa polarité ; scores sur les phrases à aspects de polarités opposées. F3 : scores avec / sans mot-clé explicite de la catégorie. F4 : supprimez les adjectifs d'opinion des phrases bien classées ; mesurez la chute. F5 : 3 graines, IC à 95 % par bootstrap (1000), McNemar entre vos deux meilleurs modèles. F6 : 30 erreurs classées (aspect implicite, catégorie voisine, polarité mixte, neutre, bruit d'annotation).
G	Tableau final : qualité, robustesse, temps d'entraînement, latence d'inférence par exemple sur CPU, taille du modèle ; matrice de confusion du modèle retenu.

QUESTIONS DU COMPTE-RENDU

Q1. Distribution des labels dans train, val et test, globalement et par entité (HOTEL, ROOMS, SERVICE…) et nombre d'aspects par phrase. Scores du classifieur trivial « toujours SERVICE#GENERAL, positive ». Quelle métrique retenez-vous, et pourquoi ?

Q2. Raccourcis (Partie A) : quels indices superficiels sont corrélés aux labels ? Que valent vos classifieurs à une seule règle ? Qu'en concluez-vous sur la validité de vos scores ?

Q3. Quels choix de prétraitement avez-vous faits par famille de modèles ? Lesquels détruisent des indices utiles (diacritiques, ponctuation, mots dialectaux) ? Chiffres à l'appui (ablation).

Q4. Zero-shot (B1) : score obtenu et sensibilité à la formulation des hypothèses. Pourquoi un modèle NLI peut-il classer sans exemple d'entraînement ? Quel rôle joue l'attention entre prémisse et hypothèse ?

Q5. Sentiment de phrase copié sur chaque aspect (B2) : où échoue-t-il, chiffres à l'appui ?

Q6. Multi-label (catégories) : seuil unique vs seuil par catégorie ; catégories rares jamais prédites. Polarité : comment traitez-vous la classe neutral ?

Q7. C1 vs C2 vs C3 (et C4) : résultats. Les poids d'attention se concentrent-ils sur les mots de l'aspect et les adjectifs d'opinion ? Effet de l'encodage positionnel ?

Q8. PLM gelé (D) vs fine-tuné (E1) : gain et coût (temps, paramètres entraînés). aubmindlab/bert-base-arabertv02 vs CAMeL-Lab/bert-base-arabic-camelbert-msa : lequel, et pourquoi ?

Q9. Multi-tâche (E2) : l'apprentissage conjoint catégories + polarité améliore-t-il la tâche principale ? Effet de λ. Pourquoi une tâche auxiliaire peut-elle aider… ou nuire ?

Q10. Décalage de prior (F1) : comparez la distribution des labels de val et de test. Écart entre le seuil (ou la règle de décision) choisi sur val et l'optimum a posteriori sur le test. Que mettriez-vous en place en production (recalibration, monitoring) ?

Q11. Entité non vue (F2) : comment le modèle traite-t-il une entité absente du train ? Qu'en conclure pour un autre domaine (restaurants) ?

Q12. Analyse d'erreurs (F6) : catégories dominantes, part du bruit d'annotation. Quel modèle mettriez-vous en production, et pourquoi (qualité, robustesse, coût, latence — chiffres à l'appui) ?

Pour tout ce qui n'est pas précisé ici (code de départ, classe MultiTask, format du compte-rendu), suivez le TP2.

Groupe 7

Ariby & Reda

Binôme

Anglais

Classification thématique multi-label de tweets + modélisation de thèmes

Attribuer à chaque tweet un ou plusieurs thèmes parmi **19** (sports, musique, business, science et technologie…). Comparer à une **modélisation de thèmes non supervisée** (BERTopic) qui découvre les thèmes sans labels.

DONNÉES

Jeu de données	TweetTopic (Antypas et al., COLING 2022), tweets en anglais.
Liens	huggingface.co/datasets/cardiffnlp/tweet_topic_multi (19 thèmes) · tweet_topic_single (6 thèmes)
Taille	Multi-label : 11 267 tweets au total, répartis en plusieurs splits.
Splits	`train_2020` / `validation_2020` (sept. 2019 – août 2020) et `test_2021` (sept. 2020 – août 2021). Autres splits utiles : `train_all`, `train_random`.

> **Métriques : macro-F1** sur les 19 thèmes (principale), micro-F1 ; NMI et ARI pour BERTopic.

POINTS D'ATTENTION

- Thèmes qui se chevauchent (pop culture, musique, célébrités).
- Dérive temporelle : les sujets de 2021 ne sont pas ceux de 2019.

Référence à citer : Antypas et al., Twitter Topic Classification, COLING 2022 — https://arxiv.org/abs/2209.09824

CONSIGNES, PARTIE PAR PARTIE

Protocole	Temporel : `train_2020` / `validation_2020` / `test_2021`. Toutes les décisions se prennent sur val ; le test reste scellé jusqu'à la Partie F. Toute transformation apprise est ajustée sur le train uniquement. Journal `results/results.csv`.
4.1 Audit	Jetons d'anonymisation (utilisateurs, URL), hashtags, emojis ; nombre de thèmes par tweet ; doublons. Doublons exacts et après normalisation (dans train, et entre train et test) ; doublons aux labels contradictoires : politique justifiée.
A	Distribution des labels, globalement et par thème et période. Classifieur trivial « toujours le thème le plus fréquent ». Baseline TF-IDF (mots 1–2 + caractères 2–5) + régression logistique one-vs-rest, seuil(s) choisi(s) sur val. Raccourcis : règles « hashtag ⇒ thème » et « mention d'un compte sportif ⇒ sports ».
B0	**B0 (topic modeling)** : BERTopic sur le train sans labels (`sentence-transformers/all-MiniLM-L6-v2`) ; alignez thèmes découverts et labels (NMI, ARI), mots-clés par thème.
B	B1 : NLI zero-shot (`MoritzLaurer/mDeBERTa-v3-base-xnli-multilingual-nli-2mil7` et `facebook/bart-large-mnli`) avec les 19 noms de thèmes comme hypothèses (« This tweet is about sports »), décision indépendante par thème ; au moins 3 formulations (anglais, français, et une reformulation), score seuillé sur val. B2 : `cardiffnlp/twitter-roberta-base-dec2021-tweet-topic-multi-all` : lisez sa fiche (données d'entraînement, split de validation) avant d'interpréter son score.
C	Vocabulaire construit sur train (fréquence ≥ 2), taux d'OOV sur val et test ; embeddings aléatoires, GloVe Twitter. C1 BiLSTM, C2 BiLSTM + attention (implémentée par vous), C3 mini-encodeur Transformer (2 couches, d_model 128, 4 têtes ; ablation sans encodage positionnel), C4 char-CNN. Déséquilibre sur le meilleur modèle : perte pondérée, sur-échantillonnage (train uniquement), seuil optimisé. Sortie : 19 sigmoïdes + BCE, seuil par thème.
D	D1 : `cardiffnlp/twitter-roberta-base-dec2021` gelé, [CLS] vs moyenne des tokens → régression logistique. D2 : états de tous les tokens → tête BiLSTM + attention de C2 ; visualisez l'attention sur 5 exemples.

E	E1 : `cardiffnlp/twitter-roberta-base-dec2021` et `roberta-base` fine-tunés ; perte pondérée, seuil choisi sur val. E2 : tête 19 thèmes + tête 6 thèmes (dataset `tweet_topic_single`, batches alternés). Départ : lr 2e-5, batch 32, 3 à 5 époques, warmup 10 %, early stopping sur val, 3 graines.
F	F1 : fréquence des thèmes en 2020 et en 2021 ; F1 par thème avec les seuils de val. F2 : dérive temporelle : `train_2020` → `test_2021` contre un split aléatoire (`train_random`) et contre `train_all`. F3 : scores avec / sans hashtags. F4 : supprimez hashtags et mentions des tweets bien classés ; mesurez la chute. F5 : 3 graines, IC à 95 % par bootstrap (1 000), McNemar entre vos deux meilleurs modèles. F6 : 30 erreurs classées (thème voisin, actualité nouvelle de 2021, tweet trop court, ironie, bruit d'annotation).
G	Tableau final : qualité, robustesse, temps d'entraînement, latence d'inférence par exemple sur CPU, taille du modèle ; matrice de confusion du modèle retenu.

QUESTIONS DU COMPTE-RENDU

Q1. Distribution des labels dans train, val et test, globalement et par thème et période. Scores du classifieur trivial « toujours le thème le plus fréquent ». Quelle métrique retenez-vous, et pourquoi ?

Q2. Raccourcis (Partie A) : quels indices superficiels sont corrélés aux labels ? Que valent vos classifieurs à une seule règle ? Qu'en concluez-vous sur la validité de vos scores ?

Q3. Quels choix de prétraitement avez-vous faits par famille de modèles ? Lesquels détruisent des indices utiles (hashtags, emojis, mentions, casse) ? Chiffres à l'appui (ablation).

Q4. BERTopic (B0) : les thèmes découverts correspondent-ils aux 19 labels (NMI, ARI) ? Lesquels fusionne-t-il ou découpe-t-il ? Zero-shot (B1) : thèmes bien et mal reconnus, sensibilité à la formulation.

Q5. Modèle B2 : son score sur `test_2021` est-il comparable aux vôtres ? Justifiez à partir de sa fiche.

Q6. Multi-label : seuil unique vs seuil par label, pondération des positifs (tableau). Quels labels restent à F1 faible, et combien d'exemples d'entraînement avaient-ils ?

Q7. C1 vs C2 vs C3 (et C4) : résultats. Les poids d'attention se concentrent-ils sur les hashtags, les noms propres et les mots du thème ? Effet de l'encodage positionnel ?

Q8. PLM gelé (D) vs fine-tuné (E1) : gain et coût (temps, paramètres entraînés). cardiffnlp/twitter-roberta-base-dec2021 vs roberta-base : lequel, et pourquoi ?

Q9. Multi-tâche (E2) : la tête à 6 thèmes améliore-t-il la tâche principale ? Effet de λ. Pourquoi une tâche auxiliaire peut-elle aider… ou nuire ?

Q10. Décalage de prior (F1) : comparez la distribution des labels de val et de test. Écart entre le seuil (ou la règle de décision) choisi sur val et l'optimum a posteriori sur le test. Que mettriez-vous en place en production (recalibration, monitoring) ?

Q11. Dérive temporelle (F2) : écart entre split aléatoire et split temporel. Que surveiller en production ?

Q12. Analyse d'erreurs (F6) : catégories dominantes, part du bruit d'annotation. Quel modèle mettriez-vous en production, et pourquoi (qualité, robustesse, coût, latence — chiffres à l'appui) ?

Pour tout ce qui n'est pas précisé ici (code de départ, classe MultiTask, format du compte-rendu), suivez le TP2.

Groupe 8

Ait Hafid

Individuel

Anglais

Détection et catégorisation fine du sexisme (anglais)

Tâche principale **B** : pour un texte sexiste, prédire sa catégorie parmi 4 (menaces, dénigrement, animosité, discussions préjudiciables). La tâche **A** (sexiste / non sexiste) sert de premier étage ; la tâche **C** (11 sous-catégories) est une extension.

DONNÉES

Jeu de données	EDOS — SemEval-2023 Tâche 10, posts Reddit et Gab.
Lien	github.com/rewire-online/edos, dossier `data/`
Fichiers	`edos_labelled_aggregated.csv` : 20 000 textes, colonnes label_sexist, label_category, label_vector et split (train 14 000 · dev 2 000 · test 4 000). `edos_labelled_individual_annotations.csv` : votes des annotateurs.
Bonus	Deux corpus non annotés (Reddit, Gab) dans le même dossier, pour un pré-entraînement adaptatif optionnel.

> **Métriques : macro-F1** sur la tâche B (principale) ; rapportez aussi A et C.

POINTS D'ATTENTION

- Hiérarchie : la catégorie n'existe que si le texte est sexiste, donc les erreurs de A se propagent à B.
- Certaines catégories sont rares, et les annotateurs ne sont pas toujours d'accord.

Référence à citer : Dépôt EDOS (article SemEval-2023 Tâche 10 cité dans le README) — https://github.com/rewire-online/edos

CONSIGNES, PARTIE PAR PARTIE

Protocole	Colonne split du fichier agrégé ; val = dev. Toutes les décisions se prennent sur val ; le test reste scellé jusqu'à la Partie F. Toute transformation apprise est ajustée sur le train uniquement. Journal `results/results.csv`.
4.1 Audit	Jetons [USER] et [URL], emojis, majuscules, textes tronqués. Doublons exacts et après normalisation (dans train, et entre train et test) ; doublons aux labels contradictoires : politique justifiée.
A	Distribution des labels, globalement et par catégorie (B) et sous-catégorie (C). Classifieur trivial « toujours non sexiste » (A) et « toujours dénigrement » (B). Baseline TF-IDF (mots 1–2 + caractères 2–5) + régression logistique `class_weight="balanced"`, seuil(s) choisi(s) sur val. Raccourcis : règle « contient un mot genré (women, woman, she, girl…) ⇒ sexiste » ; taux de sexisme selon la présence d'insultes.
B	B1 : NLI zero-shot (`MoritzLaurer/mDeBERTa-v3-base-xnli-multilingual-nli-2mil7` et `facebook/bart-large-mnli`) avec une hypothèse par catégorie (« This text threatens women », « This text insults women »…) ; au moins 3 formulations (anglais, français, et une reformulation), score seuillé sur val. B2 : `facebook/roberta-hate-speech-dynabench-r4-target` + règle « hate ⇒ sexiste », puis catégorie par NLI.
C	Vocabulaire construit sur train (fréquence ≥ 2), taux d'OOV sur val et test ; embeddings aléatoires, GloVe ou fastText anglais. C1 BiLSTM, C2 BiLSTM + attention (implémentée par vous), C3 mini-encodeur Transformer (2 couches, d_model 128, 4 têtes ; ablation sans encodage positionnel), C4 char-CNN. Déséquilibre sur le meilleur modèle : perte pondérée, sur-échantillonnage (train uniquement), seuil optimisé.
D	D1 : `roberta-base` gelé, [CLS] vs moyenne des tokens → régression logistique. D2 : états de tous les tokens → tête BiLSTM + attention de C2 ; visualisez l'attention sur 5 exemples.
E	E1 : `roberta-base` et `microsoft/deberta-v3-base` fine-tunés ; perte pondérée, seuil choisi sur val. E2 : multi-tâche hiérarchique : têtes A (2 classes), B (5 = none + 4) et option C, λ choisis sur val. Départ : lr 2e-5, batch 32, 3 à 5 époques, warmup 10 %, early stopping sur val, 3 graines.

F	F1 : comparez la distribution des labels de val et de test ; score sur le test avec le seuil choisi sur val, puis F1 = f(seuil) a posteriori (analyse, pas sélection). F2 : accord des annotateurs : à partir du fichier des annotations individuelles, séparez les textes à vote unanime et partagé ; scores sur chaque groupe. F3 : scores avec / sans mot genré explicite. F4 : supprimez insultes et mots genrés des textes sexistes bien détectés ; mesurez la chute. F5 : 3 graines, IC à 95 % par bootstrap (1 000), McNemar entre vos deux meilleurs modèles. F6 : 30 erreurs classées (sous-entendu, sarcasme, citation ou discussion du sexisme, catégorie voisine, bruit d'annotation).
G	Tableau final : qualité, robustesse, temps d'entraînement, latence d'inférence par exemple sur CPU, taille du modèle ; matrice de confusion du modèle retenu.

QUESTIONS DU COMPTE-RENDU

Q1. Distribution des labels dans train, val et test, globalement et par catégorie (B) et sous-catégorie (C). Scores du classifieur trivial « toujours non sexiste » (A) et « toujours dénigrement » (B). Quelle métrique retenez-vous, et pourquoi ?

Q2. Raccourcis (Partie A) : quels indices superficiels sont corrélés aux labels ? Que valent vos classifieurs à une seule règle ? Qu'en concluez-vous sur la validité de vos scores ?

Q3. Quels choix de prétraitement avez-vous faits par famille de modèles ? Lesquels détruisent des indices utiles (casse, emojis, ponctuation, jetons [USER]) ? Chiffres à l'appui (ablation).

Q4. Zero-shot (B1) : score obtenu et sensibilité à la formulation des hypothèses. Pourquoi un modèle NLI peut-il classer sans exemple d'entraînement ? Quel rôle joue l'attention entre prémisse et hypothèse ?

Q5. Le détecteur de haine existant (B2) repère-t-il le sexisme ? Quelles catégories rate-t-il ?

Q6. Déséquilibre : comparez pondération de la perte, sur-échantillonnage et optimisation du seuil (tableau). Pourquoi le sur-échantillonnage doit-il être fait après la séparation train / val ?

Q7. C1 vs C2 vs C3 (et C4) : résultats. Les poids d'attention se concentrent-ils sur les termes genrés et les insultes ? Effet de l'encodage positionnel ?

Q8. PLM gelé (D) vs fine-tuné (E1) : gain et coût (temps, paramètres entraînés). roberta-base vs microsoft/deberta-v3-base : lequel, et pourquoi ?

Q9. Multi-tâche (E2) : l'ajout des têtes A et C améliore-t-il la tâche principale ? Effet de λ. Pourquoi une tâche auxiliaire peut-elle aider… ou nuire ?

Q10. Décalage de prior (F1) : comparez la distribution des labels de val et de test. Écart entre le seuil (ou la règle de décision) choisi sur val et l'optimum a posteriori sur le test. Que mettriez-vous en place en production (recalibration, monitoring) ?

Q11. Textes unanimes vs partagés (F2) : écart de score. Quel plafond de F1 vous paraît réaliste pour la tâche B, et pourquoi ?

Q12. Analyse d'erreurs (F6) : catégories dominantes, part du bruit d'annotation. Quel modèle mettriez-vous en production, et pourquoi (qualité, robustesse, coût, latence — chiffres à l'appui) ?

Pour tout ce qui n'est pas précisé ici (code de départ, classe MultiTask, format du compte-rendu), suivez le TP2.

Groupe 9

Sakhi

Individuel

Arabe

Repérer les affirmations qui méritent une vérification (arabe)

Décider si un tweet arabe contient une affirmation factuelle qui mérite d'être vérifiée : **Yes** / **No**. On ne juge pas si l'affirmation est vraie (différent du TP1).

DONNÉES

Jeu de données	CLEF CheckThat! 2024, Tâche 1 (check-worthiness), partie arabe.
Lien	gitlab.com/checkthat_lab/clef2024-checkthat-lab, dossier `task1`
Taille	train 7 333 · dev 1 093 · dev-test 500 · test 610.
Anglais	Les données anglaises de la même tâche (même dépôt) servent à la Partie E2.

> **Métriques : F1 de la classe Yes** (principale), PR-AUC, macro-F1.

POINTS D'ATTENTION

- Notion subjective : « mérite d'être vérifié » dépend de l'importance et de l'intérêt public.
- Les splits n'ont pas tous la même proportion de Yes.

Référence à citer : Overview CLEF-2024 CheckThat! Tâche 1 — https://ceur-ws.org/Vol-3740/paper-24.pdf

CONSIGNES, PARTIE PAR PARTIE

Protocole	val = dev ; dev-test = second test « décalé » utilisé en Partie F1 ; test officiel scellé jusqu'à la Partie F. Toutes les décisions se prennent sur val ; le test reste scellé jusqu'à la Partie F. Toute transformation apprise est ajustée sur le train uniquement. Journal `results/results.csv`.
4.1 Audit	Comptez URL, mentions, hashtags, nombres, noms de pays et d'institutions ; doublons et quasi-doublons (retweets). Doublons exacts et après normalisation (dans train, et entre train et test) ; doublons aux labels contradictoires : politique justifiée.
A	Distribution des labels, globalement et par split (dev, dev-test, test) et présence d'un nombre. Classifieur trivial « toujours No ». Baseline TF-IDF (mots 1–2 + caractères 2–5) + régression logistique `class_weight="balanced"`, seuil(s) choisi(s) sur val. Raccourcis : règles « contient un nombre ⇒ Yes », « contient une URL ⇒ Yes », « cite un pays ou une institution ⇒ Yes ».
B	B1 : NLI zero-shot (`MoritzLaurer/mDeBERTa-v3-base-xnli-multilingual-nli-2mil7`) avec « Ce tweet contient une affirmation factuelle importante qu'il faut vérifier » vs « Ce tweet est une opinion » ; au moins 3 formulations (arabe, français, anglais), score seuillé sur val. B2 : `CAMeL-Lab/bert-base-arabic-camelbert-mix-ner` + règle « au moins une entité nommée et un nombre ⇒ Yes ».
C	Vocabulaire construit sur train (fréquence ≥ 2), taux d'OOV sur val et test ; embeddings aléatoires, AraVec Twitter (figé puis dégelé). C1 BiLSTM, C2 BiLSTM + attention (implémentée par vous), C3 mini-encodeur Transformer (2 couches, d_model 128, 4 têtes ; ablation sans encodage positionnel), C4 char-CNN. Déséquilibre sur le meilleur modèle : perte pondérée, sur-échantillonnage (train uniquement), seuil optimisé.
D	D1 : `aubmindlab/bert-base-arabertv02-twitter` gelé, [CLS] vs moyenne des tokens → régression logistique. D2 : états de tous les tokens → tête BiLSTM + attention de C2 ; visualisez l'attention sur 5 exemples.
E	E1 : `aubmindlab/bert-base-arabertv02-twitter` et `UBC-NLP/MARBERTv2` fine-tunés ; perte pondérée, seuil choisi sur val. E2 : multi-tâche multilingue : encodeur `xlm-roberta-base`, une tête arabe et une tête anglaise, λ sur la perte anglaise. Départ : lr 2e-5, batch 32, 3 à 5 époques, warmup 10 %, early stopping sur val, 3 graines.

F	F1 : seuil choisi sur dev, appliqué tel quel au dev-test puis au test ; tracez F1 = f(seuil) a posteriori sur les deux. F2 : dev-test comme domaine décalé : comparez avec le test et analysez les thèmes des erreurs. F3 : scores avec / sans nombre et avec / sans URL ; réentraînez en masquant les nombres. F4 : supprimez nombres et entités des tweets Yes bien détectés ; mesurez la chute. F5 : 3 graines, IC à 95 % par bootstrap (1 000), McNemar entre vos deux meilleurs modèles. F6 : 30 erreurs classées (opinion déguisée en fait, affirmation banale, affirmation invérifiable, contexte manquant, bruit d'annotation).
G	Tableau final : qualité, robustesse, temps d'entraînement, latence d'inférence par exemple sur CPU, taille du modèle ; matrice de confusion du modèle retenu.

QUESTIONS DU COMPTE-RENDU

Q1. Distribution des labels dans train, val et test, globalement et par split (dev, dev-test, test) et présence d'un nombre. Scores du classifieur trivial « toujours No ». Quelle métrique retenez-vous, et pourquoi ?

Q2. Raccourcis (Partie A) : quels indices superficiels sont corrélés aux labels ? Que valent vos classifieurs à une seule règle ? Qu'en concluez-vous sur la validité de vos scores ?

Q3. Quels choix de prétraitement avez-vous faits par famille de modèles ? Lesquels détruisent des indices utiles (nombres, URL, hashtags, ponctuation) ? Chiffres à l'appui (ablation).

Q4. Zero-shot (B1) : score obtenu et sensibilité à la formulation des hypothèses. Pourquoi un modèle NLI peut-il classer sans exemple d'entraînement ? Quel rôle joue l'attention entre prémisse et hypothèse ?

Q5. La règle « entité + nombre ⇒ Yes » (B2) : précision, rappel, F1. Que révèle-t-elle de la tâche ?

Q6. Déséquilibre : comparez pondération de la perte, sur-échantillonnage et optimisation du seuil (tableau). Pourquoi le sur-échantillonnage doit-il être fait après la séparation train / val ?

Q7. C1 vs C2 vs C3 (et C4) : résultats. Les poids d'attention se concentrent-ils sur les nombres, les entités nommées et les verbes de déclaration ? Effet de l'encodage positionnel ?

Q8. PLM gelé (D) vs fine-tuné (E1) : gain et coût (temps, paramètres entraînés). aubmindlab/bert-base-arabertv02-twitter vs UBC-NLP/MARBERTv2 : lequel, et pourquoi ?

Q9. Multi-tâche (E2) : l'ajout des données anglaises améliore-t-il la tâche principale ? Effet de λ. Pourquoi une tâche auxiliaire peut-elle aider… ou nuire ?

Q10. Décalage de prior (F1) : part de Yes dans dev, dev-test et test. Écart entre le seuil choisi sur dev et le seuil optimal a posteriori sur dev-test et test. Que mettriez-vous en place en production ?

Q11. Multilingue (E2, F2) : les données anglaises aident-elles l'arabe ? Que vaut le modèle arabe appliqué aux tweets anglais, et inversement ?

Q12. Analyse d'erreurs (F6) : catégories dominantes, part du bruit d'annotation. Quel modèle mettriez-vous en production, et pourquoi (qualité, robustesse, coût, latence — chiffres à l'appui) ?

Pour tout ce qui n'est pas précisé ici (code de départ, classe MultiTask, format du compte-rendu), suivez le TP2.

Groupe 10

Hamouchi & Bendahmar

Binôme

Arabe

Détection des techniques de persuasion en arabe

Sous-tâche **1A** : le texte (tweet ou paragraphe d'article) contient-il une technique de persuasion ? Sous-tâche **1B** (principale) : lesquelles, parmi **23** techniques (langage chargé, étiquetage, appel à la peur…), en multi-label.

DONNÉES

Jeu de données	ArAIEval 2023, Tâche 1 (ArabicNLP 2023).
Lien	araieval.gitlab.io (page de la tâche, avec le lien vers les données sur GitLab)
Taille	2 427 train · 259 dev · 503 test, tweets et paragraphes de presse mélangés.

> **Métriques : micro-F1** (métrique officielle) et **macro-F1** pour 1B ; F1 pour 1A.

POINTS D'ATTENTION

- 23 labels pour environ 2 400 exemples : une longue traîne extrême.
- Deux genres de textes (tweets et presse) dans les mêmes splits ; les techniques se recouvrent.

Référence à citer : Hasanain et al., ArAIEval Shared Task, ArabicNLP 2023 — https://arxiv.org/abs/2311.03179

CONSIGNES, PARTIE PAR PARTIE

Protocole	train / dev / test de la Tâche 1 ; val = dev. Toutes les décisions se prennent sur val ; le test reste scellé jusqu'à la Partie F. Toute transformation apprise est ajustée sur le train uniquement. Journal `results/results.csv`.
4.1 Audit	Distinguez tweets et paragraphes de presse (longueur, URL, mentions) ; fréquence de chaque technique ; doublons. Doublons exacts et après normalisation (dans train, et entre train et test) ; doublons aux labels contradictoires : politique justifiée.
A	Distribution des labels, globalement et par genre (tweet / presse) et technique. Classifieur trivial « classifieur majoritaire » (1A et 1B). Baseline TF-IDF (mots 1–2 + caractères 2–5) + régression logistique one-vs-rest, seuil(s) choisi(s) sur val. Raccourcis : règles « contient un mot très négatif ⇒ langage chargé » et « genre ⇒ persuasif ».
B	B1 : NLI zero-shot (`MoritzLaurer/mDeBERTa-v3-base-xnli-multilingual-nli-2mil7`) avec la définition de chaque technique comme hypothèse ; au moins 3 formulations (arabe, français, anglais), score seuillé sur val. B2 : `CAMeL-Lab/bert-base-arabic-camelbert-da-sentiment` + règle « négatif ⇒ langage chargé ».
C	Vocabulaire construit sur train (fréquence ≥ 2), taux d'OOV sur val et test ; embeddings aléatoires, AraVec (figé puis dégelé). C1 BiLSTM, C2 BiLSTM + attention (implémentée par vous), C3 mini-encodeur Transformer (2 couches, d_model 128, 4 têtes ; ablation sans encodage positionnel), C4 char-CNN. Déséquilibre sur le meilleur modèle : perte pondérée, sur-échantillonnage (train uniquement), seuil optimisé. Sortie 1B : 23 sigmoïdes, seuils par technique ; option : regrouper les techniques rares en familles.
D	D1 : `aubmindlab/bert-base-arabertv02-twitter` gelé, [CLS] vs moyenne des tokens → régression logistique. D2 : états de tous les tokens → tête BiLSTM + attention de C2 ; visualisez l'attention sur 5 exemples.
E	E1 : `aubmindlab/bert-base-arabertv02-twitter` et `UBC-NLP/MARBERTv2` fine-tunés ; perte pondérée, seuil choisi sur val. E2 : tête 1A (binaire) + tête 1B (23 sigmoïdes) sur un encodeur partagé. Départ : lr 2e-5, batch 32, 3 à 5 époques, warmup 10 %, early stopping sur val, 3 graines.

F	F1 : comparez la distribution des labels de val et de test ; score sur le test avec le seuil choisi sur val, puis F1 = f(seuil) a posteriori (analyse, pas sélection). F2 : genre non vu : entraînez sur la presse, testez sur les tweets, et inversement. F3 : scores selon la longueur du texte et le genre. F4 : supprimez les mots chargés des textes bien classés ; mesurez la chute. F5 : 3 graines, IC à 95 % par bootstrap (1 000), McNemar entre vos deux meilleurs modèles. F6 : 30 erreurs classées (technique implicite, techniques voisines, ironie, contexte manquant, bruit d'annotation).
G	Tableau final : qualité, robustesse, temps d'entraînement, latence d'inférence par exemple sur CPU, taille du modèle ; matrice de confusion du modèle retenu.

QUESTIONS DU COMPTE-RENDU

Q1. Fréquence de chaque technique dans train, dev et test, par genre. Classifieur majoritaire : micro-F1 et macro-F1. Pourquoi les deux métriques racontent-elles deux histoires différentes ici ? Laquelle défendre ?

Q2. Raccourcis (Partie A) : quels indices superficiels sont corrélés aux labels ? Que valent vos classifieurs à une seule règle ? Qu'en concluez-vous sur la validité de vos scores ?

Q3. Quels choix de prétraitement avez-vous faits par famille de modèles ? Lesquels détruisent des indices utiles (ponctuation, emojis, mots chargés) ? Chiffres à l'appui (ablation).

Q4. Zero-shot (B1) : score obtenu et sensibilité à la formulation des hypothèses. Pourquoi un modèle NLI peut-il classer sans exemple d'entraînement ? Quel rôle joue l'attention entre prémisse et hypothèse ?

Q5. Transfert sans entraînement (B2) : précision, rappel, F1. Que révèle-t-il de la tâche ? Son score est-il exempt de contamination ?

Q6. Longue traîne : seuils par technique, pondération, regroupement en familles (tableau). Combien de techniques restent à F1 nul ?

Q7. C1 vs C2 vs C3 (et C4) : résultats. Les poids d'attention se concentrent-ils sur les mots chargés, les insultes et les appels à l'émotion ? Effet de l'encodage positionnel ?

Q8. PLM gelé (D) vs fine-tuné (E1) : gain et coût (temps, paramètres entraînés). aubmindlab/bert-base-arabertv02-twitter vs UBC-NLP/MARBERTv2 : lequel, et pourquoi ?

Q9. Multi-tâche (E2) : la tête binaire 1A améliore-t-il la tâche principale ? Effet de λ. Pourquoi une tâche auxiliaire peut-elle aider… ou nuire ?

Q10. Décalage de prior (F1) : comparez la distribution des labels de val et de test. Écart entre le seuil (ou la règle de décision) choisi sur val et l'optimum a posteriori sur le test. Que mettriez-vous en place en production (recalibration, monitoring) ?

Q11. Genre non vu (F2) : chute presse → tweets et inverse. Techniques jamais détectées : combien d'exemples d'entraînement avaient-elles ?

Q12. Analyse d'erreurs (F6) : catégories dominantes, part du bruit d'annotation. Quel modèle mettriez-vous en production, et pourquoi (qualité, robustesse, coût, latence — chiffres à l'appui) ?

Pour tout ce qui n'est pas précisé ici (code de départ, classe MultiTask, format du compte-rendu), suivez le TP2.

Groupe 11

Jamila & Moutik

Binôme

Anglais

Identifier les valeurs humaines derrière un argument

Pour un argument (prémisse, position pour / contre, conclusion), prédire les **valeurs humaines** qu'il mobilise parmi **20** catégories (Schwartz), en multi-label : tradition, sécurité sociétale, bienveillance, hédonisme...

DONNÉES

Jeu de données	Touché23-ValueEval — SemEval-2023 Tâche 4, en anglais.
Lien	doi.org/10.5281/zenodo.6814563 (Zenodo, accès libre)
Taille	Principal : 5 393 train · 1 896 val · 1 576 test. Tests supplémentaires : Nahj al-Balagha (279, texte religieux islamique traduit), New York Times (80) ; val supplémentaire Zhihu (100).

> **Métriques : macro-F1** sur les 20 valeurs (principale), F1 par valeur.

POINTS D'ATTENTION

- Concepts abstraits : la valeur est rarement nommée dans le texte.
- Deux tests hors domaine (texte religieux, presse) sont fournis avec le dataset.

Référence à citer : Kiesel et al., SemEval-2023 Task 4: ValueEval — https://aclanthology.org/2023.semeval-1.313

CONSIGNES, PARTIE PAR PARTIE

Protocole	training / validation / test du jeu principal ; tests Nahj al-Balagha et NYT scellés jusqu'à la Partie F. Toutes les décisions se prennent sur val ; le test reste scellé jusqu'à la Partie F. Toute transformation apprise est ajustée sur le train uniquement. Journal `results/results.csv`.
4.1 Audit	Longueur des prémisses, conclusions répétées entre arguments, doublons, nombre de valeurs par argument. Doublons exacts et après normalisation (dans train, et entre train et test) ; doublons aux labels contradictoires : politique justifiée.
A	Distribution des labels, globalement et par position (pour / contre) et valeur. Classifieur trivial « toutes les valeurs » et « aucune valeur ». Baseline TF-IDF (mots 1–2 + caractères 2–5) + régression logistique one-vs-rest, seuil(s) choisi(s) sur val. Raccourcis : dictionnaire de mots-clés par valeur ; corrélation entre une conclusion et ses valeurs (une même conclusion apparaît-elle dans train et test ?).
B	B1 : NLI zero-shot (`MoritzLaurer/mDeBERTa-v3-base-xnli-multilingual-nli-2mil7` et `facebook/bart-large-mnli`) avec une description de chaque valeur comme hypothèse ; au moins 3 formulations (anglais, français, et une reformulation), score seuillé sur val. B2 : votre dictionnaire de mots-clés utilisé seul, comme système sans entraînement.
C	Vocabulaire construit sur train (fréquence ≥ 2), taux d'OOV sur val et test ; embeddings aléatoires, GloVe ou fastText anglais. C1 BiLSTM, C2 BiLSTM + attention (implémentée par vous), C3 mini-encodeur Transformer (2 couches, d_model 128, 4 têtes ; ablation sans encodage positionnel), C4 char-CNN. Déséquilibre sur le meilleur modèle : perte pondérée, sur-échantillonnage (train uniquement), seuil optimisé. Entrée : conclusion, position et prémisse concaténées. Sortie : 20 sigmoïdes, seuil par valeur.
D	D1 : `roberta-base` gelé, [CLS] vs moyenne des tokens → régression logistique. D2 : états de tous les tokens → tête BiLSTM + attention de C2 ; visualisez l'attention sur 5 exemples.
E	E1 : `roberta-base` et `microsoft/deberta-v3-base` fine-tunés, entrée « conclusion [SEP] position [SEP] prémisse » ; perte pondérée, seuil choisi sur val. E2 : tête 20 valeurs + tête des 4 dimensions de Schwartz (ouverture au changement, affirmation de soi, continuité, dépassement de soi), dérivées des 20. Départ : lr 2e-5, batch 32, 3 à 5 époques, warmup 10 %, early stopping sur val, 3 graines.

F	F1 : fréquence des valeurs dans val et test ; F1 par valeur avec les seuils de val. F2 : hors domaine : Nahj al-Balagha et NYT avec le seuil choisi sur val. F3 : scores sur les arguments dont la conclusion est / n'est pas vue dans le train. F4 : supprimez les mots-clés de valeur des arguments bien classés ; mesurez la chute. F5 : 3 graines, IC à 95 % par bootstrap (1 000), McNemar entre vos deux meilleurs modèles. F6 : 30 erreurs classées (valeur implicite, valeurs voisines, argument ambigu, style religieux ou journalistique, bruit d'annotation).
G	Tableau final : qualité, robustesse, temps d'entraînement, latence d'inférence par exemple sur CPU, taille du modèle ; matrice de confusion du modèle retenu.

QUESTIONS DU COMPTE-RENDU

Q1. Distribution des labels dans train, val et test, globalement et par position (pour / contre) et valeur. Scores du classifieur trivial « toutes les valeurs » et « aucune valeur ». Quelle métrique retenez-vous, et pourquoi ?

Q2. Raccourcis (Partie A) : quels indices superficiels sont corrélés aux labels ? Que valent vos classifieurs à une seule règle ? Qu'en concluez-vous sur la validité de vos scores ?

Q3. Quels choix de prétraitement avez-vous faits par famille de modèles ? Lesquels détruisent des indices utiles (négations, mots moraux, casse) ? Chiffres à l'appui (ablation).

Q4. Zero-shot (B1) : quelles valeurs le NLI reconnaît-il bien, lesquelles jamais ? Sensibilité à la description de la valeur et à la langue de l'hypothèse.

Q5. Transfert sans entraînement (B2) : précision, rappel, F1. Que révèle-t-il de la tâche ? Son score est-il exempt de contamination ?

Q6. Multi-label : seuil unique vs seuil par label, pondération des positifs (tableau). Quels labels restent à F1 faible, et combien d'exemples d'entraînement avaient-ils ?

Q7. C1 vs C2 vs C3 (et C4) : résultats. Les poids d'attention se concentrent-ils sur les mots de la conclusion et les termes moraux ? Effet de l'encodage positionnel ?

Q8. PLM gelé (D) vs fine-tuné (E1) : gain et coût (temps, paramètres entraînés). roberta-base vs microsoft/deberta-v3-base : lequel, et pourquoi ?

Q9. Multi-tâche (E2) : la tête des 4 dimensions améliore-t-il la tâche principale ? Effet de λ. Pourquoi une tâche auxiliaire peut-elle aider… ou nuire ?

Q10. Décalage de prior (F1) : comparez la distribution des labels de val et de test. Écart entre le seuil (ou la règle de décision) choisi sur val et l'optimum a posteriori sur le test. Que mettriez-vous en place en production (recalibration, monitoring) ?

Q11. Hors domaine (F2) : chute sur Nahj al-Balagha et sur NYT. Vocabulaire, style ou valeurs différentes ? Exemples à l'appui.

Q12. Analyse d'erreurs (F6) : catégories dominantes, part du bruit d'annotation. Quel modèle mettriez-vous en production, et pourquoi (qualité, robustesse, coût, latence — chiffres à l'appui) ?

Pour tout ce qui n'est pas précisé ici (code de départ, classe MultiTask, format du compte-rendu), suivez le TP2.

Groupe 12

El Khali

Individuel

Darija

Analyse de sentiment en darija, en alphabet arabe et latin

Classer chaque tweet marocain en **positive**, **negative** ou **neutral**. Une grande partie des tweets est écrite en arabizi (darija en alphabet latin).

DONNÉES

Jeu de données	AfriSenti — SemEval-2023 Tâche 12, langue Moroccan Darija (ary).
Lien	github.com/afrisenti-semeval/afrisent-semeval-2023, dossier `data/ary/`
Fichiers	`train.tsv` (5 583) · `dev.tsv` (494) · `test.tsv` (2 961), colonnes tweet, label.
Votes	Votes individuels des annotateurs : dossier `data_with_annotators_labels/`.
Algérien	`data/arq/` (même format) sert à la Partie E2.

> **Métriques : F1 pondéré** (métrique officielle) et macro-F1.

POINTS D'ATTENTION

- Deux alphabets, orthographe libre, mélange darija / français / MSA.
- Vérifiez si l'écriture est liée au label, et si sa proportion change entre train et test.

Référence à citer : Muhammad et al., AfriSenti (dataset) — https://arxiv.org/abs/2302.08956

CONSIGNES, PARTIE PAR PARTIE

Protocole	train / dev / test officiels ; val = dev. Toutes les décisions se prennent sur val ; le test reste scellé jusqu'à la Partie F. Toute transformation apprise est ajustée sur le train uniquement. Journal `results/results.csv`.
4.1 Audit	Mesurez la part de tweets en écriture latine (arabizi), arabe et mixte ; chiffres utilisés comme lettres (3, 7, 9) ; mots français ; emojis. Doublons exacts et après normalisation (dans train, et entre train et test) ; doublons aux labels contradictoires : politique justifiée.
A	Distribution des labels, globalement et par écriture (arabe / latine). Classifieur trivial « classe majoritaire ». Baseline TF-IDF (mots 1–2 + caractères 2–5) + régression logistique `class_weight="balanced"`, seuil(s) choisi(s) sur val. Raccourcis : taux de chaque classe selon l'écriture ; règle fondée uniquement sur l'écriture du tweet.
B	B1 : NLI zero-shot (`MoritzLaurer/mDeBERTa-v3-base-xnli-multilingual-nli-2mil7`) avec positif / négatif / neutre ; au moins 3 formulations (arabe, français, anglais), score seuillé sur val. B2 : `CAMeL-Lab/bert-base-arabic-camelbert-da-sentiment` (lit l'alphabet arabe seulement) : scores séparés par écriture.
C	Vocabulaire construit sur train (fréquence ≥ 2), taux d'OOV sur val et test ; embeddings AraVec (arabe seulement) vs fastText entraîné sur votre train (couvre l'arabizi) : OOV par écriture. C1 BiLSTM, C2 BiLSTM + attention (implémentée par vous), C3 mini-encodeur Transformer (2 couches, d_model 128, 4 têtes ; ablation sans encodage positionnel), C4 char-CNN. Déséquilibre sur le meilleur modèle : perte pondérée, sur-échantillonnage (train uniquement), seuil optimisé. Le char-CNN (C4) est particulièrement utile ici.
D	D1 : `SI2M-Lab/DarijaBERT` gelé, [CLS] vs moyenne des tokens → régression logistique. D2 : états de tous les tokens → tête BiLSTM + attention de C2 ; visualisez l'attention sur 5 exemples.
E	E1 : `SI2M-Lab/DarijaBERT` et `SI2M-Lab/DarijaBERT-arabizi` (option : `UBC-NLP/MARBERTv2`) fine-tunés ; perte pondérée, seuil choisi sur val. E2 : tête ary + tête arq (algérien) sur un encodeur partagé ; option : cible souple tirée des votes individuels. Départ : lr 2e-5, batch 32, 3 à 5 époques, warmup 10 %, early stopping sur val, 3 graines.

F	F1 : comparez la distribution des labels de val et de test ; score sur le test avec le seuil choisi sur val, puis F1 = f(seuil) a posteriori (analyse, pas sélection). F2 : écriture non vue : entraînez sur les tweets en arabe seulement, testez sur les tweets latins, et inversement. F3 : scores par écriture ; option : translittération arabizi → arabe avant le modèle. F4 : supprimez emojis et ponctuation répétée des tweets polarisés bien classés ; mesurez la chute. F5 : 3 graines, IC à 95 % par bootstrap (1000), McNemar entre vos deux meilleurs modèles. F6 : 30 erreurs classées (ironie, arabizi mal tokenisé, mélange avec le français, neutre vs polarisé, bruit d'annotation).
G	Tableau final : qualité, robustesse, temps d'entraînement, latence d'inférence par exemple sur CPU, taille du modèle ; matrice de confusion du modèle retenu.

QUESTIONS DU COMPTE-RENDU

Q1. Distribution des labels dans train, val et test, globalement et par écriture (arabe / latine). Scores du classifieur trivial « classe majoritaire ». Quelle métrique retenez-vous, et pourquoi ?

Q2. Raccourcis : la distribution des labels dépend-elle de l'écriture ? Que vaut la règle fondée sur l'écriture ? Qu'en concluez-vous sur la validité de vos scores ?

Q3. Quels choix de prétraitement avez-vous faits par famille de modèles ? Lesquels détruisent des indices utiles (emojis, lettres répétées, mots français, arabizi) ? Chiffres à l'appui (ablation).

Q4. Zero-shot (B1) : score obtenu et sensibilité à la formulation des hypothèses. Pourquoi un modèle NLI peut-il classer sans exemple d'entraînement ? Quel rôle joue l'attention entre prémisse et hypothèse ?

Q5. Modèle de sentiment B2 : scores sur les tweets arabes et latins séparément. Pourquoi cet écart ? Son score est-il exempt de contamination ?

Q6. Déséquilibre : comparez pondération de la perte, sur-échantillonnage et optimisation du seuil (tableau). Pourquoi le sur-échantillonnage doit-il être fait après la séparation train / val ?

Q7. C1 vs C2 vs C3 (et C4) : résultats. Les poids d'attention se concentrent-ils sur les emojis, les mots d'opinion et les mots français ? Effet de l'encodage positionnel ?

Q8. PLM gelé (D) vs fine-tuné (E1) : gain et coût (temps, paramètres entraînés). SI2M-Lab/DarijaBERT vs SI2M-Lab/DarijaBERT-arabizi : lequel, et pourquoi ?

Q9. Multi-tâche (E2) : l'ajout de l'algérien améliore-t-il la tâche principale ? Effet de λ. Pourquoi une tâche auxiliaire peut-elle aider… ou nuire ?

Q10. Décalage de prior (F1) : comparez la distribution des labels de val et de test. Écart entre le seuil (ou la règle de décision) choisi sur val et l'optimum a posteriori sur le test. Que mettriez-vous en place en production (recalibration, monitoring) ?

Q11. Écriture non vue (F2) : chute mesurée. Quel modèle déployer pour des commentaires marocains mêlant les deux écritures, et pourquoi ?

Q12. Analyse d'erreurs (F6) : catégories dominantes, part du bruit d'annotation. Quel modèle mettriez-vous en production, et pourquoi (qualité, robustesse, coût, latence — chiffres à l'appui) ?

Pour tout ce qui n'est pas précisé ici (code de départ, classe MultiTask, format du compte-rendu), suivez le TP2.

Groupe 13

Badereddine

Individuel

Arabe

Classification des actes de langage dans les tweets arabes

Prédire l'acte de langage d'un tweet : **Expression, Assertion, Question, Request, Recommendation, Miscellaneous**. Fusionner Recommendation et Miscellaneous est permis si c'est justifié.

DONNÉES

Jeu de données	ArSAS — Arabic Speech-Act and Sentiment corpus (Elmadany, Mubarak et Magdy, 2018).
Lien	homepages.inf.ed.ac.uk/wmagdy/Resources/ArSAS.zip (page : resources.htm)
Taille	21 064 tweets sur 20 sujets controversés, de 3 types : long-standing, entity, event.
Annotations	Acte de langage (6 classes) et sentiment (4 classes : positif, négatif, neutre, mixte).

> **Métriques : macro-F1** (principale) et F1 par classe. L'accuracy n'est pas acceptable.

POINTS D'ATTENTION

- Trois classes représentent chacune moins de 1 % du corpus.
- La frontière entre Expression et Assertion est souvent ambiguë ; les questions rhétoriques ne sont pas de vraies questions.

Référence à citer : Elmadany, Mubarak et Magdy, ArSAS, 2018 — https://www.pure.ed.ac.uk/ws/files/54743525/arabic_speech_act.pdf

CONSIGNES, PARTIE PAR PARTIE

Protocole	Pas de split officiel : test = 20 % stratifié sur l'acte de langage (`random_state=42`), puis val = 10 % stratifié du reste. Toutes les décisions se prennent sur val ; le test reste scellé jusqu'à la Partie F. Toute transformation apprise est ajustée sur le train uniquement. Journal `results/results.csv`.
4.1 Audit	Ponctuation (؟ ! …), emojis, URL, mentions, hashtags ; doublons et retweets ; vérifiez que chaque tweet porte son sujet. Doublons exacts et après normalisation (dans train, et entre train et test) ; doublons aux labels contradictoires : politique justifiée.
A	Distribution des labels, globalement et par type de sujet (long-standing / entity / event). Classifieur trivial « toujours Expression ». Baseline TF-IDF (mots 1–2 + caractères 2–5) + régression logistique `class_weight="balanced"`, seuil(s) choisi(s) sur val. Raccourcis : règles « contient ؟ ⇒ Question » et « contient يجب ou لازم ⇒ Recommendation ».
B	B1 : NLI zero-shot (`MoritzLaurer/mDeBERTa-v3-base-xnli-multilingual-nli-2mil7`) avec une hypothèse par acte (« Ce tweet pose une question », « Ce tweet exprime une émotion »…) ; au moins 3 formulations (arabe, français, anglais), score seuillé sur val. B2 : `CAMeL-Lab/bert-base-arabic-camelbert-da-sentiment` sur la tâche auxiliaire sentiment. Piège : ce modèle a été fine-tuné notamment sur ArSAS (voir TP2).
C	Vocabulaire construit sur train (fréquence ≥ 2), taux d'OOV sur val et test ; embeddings aléatoires, AraVec Twitter (figé puis dégelé). C1 BiLSTM, C2 BiLSTM + attention (implémentée par vous), C3 mini-encodeur Transformer (2 couches, d_model 128, 4 têtes ; ablation sans encodage positionnel), C4 char-CNN. Déséquilibre sur le meilleur modèle : perte pondérée, sur-échantillonnage (train uniquement), seuil optimisé. Déséquilibre : comparez perte pondérée, sur-échantillonnage, seuils par classe et focal loss sur les 3 classes rares.
D	D1 : `aubmindlab/bert-base-arabertv02-twitter` gelé, [CLS] vs moyenne des tokens → régression logistique. D2 : états de tous les tokens → tête BiLSTM + attention de C2 ; visualisez l'attention sur 5 exemples.
E	E1 : `aubmindlab/bert-base-arabertv02-twitter` et `UBC-NLP/MARBERTv2` fine-tunés ; perte pondérée, seuil choisi sur val. E2 : acte de langage + sentiment (4 classes), mêmes tweets. Départ : lr 2e-5, batch 32, 3 à 5 époques, warmup 10 %, early stopping sur val, 3 graines.

F	F1 : comparez la distribution des labels de val et de test ; score sur le test avec le seuil choisi sur val, puis F1 = f(seuil) a posteriori (analyse, pas sélection). F2 : type de sujet non vu : entraînez sans les tweets « event », testez sur eux. F3 : scores avec / sans « ʕ » ; réentraînez en supprimant la ponctuation. F4 : supprimez la ponctuation finale des Question et Request bien détectées ; mesurez la chute. F5 : 3 graines, IC à 95 % par bootstrap (1000), McNemar entre vos deux meilleurs modèles. F6 : 30 erreurs classées (question rhétorique, expression vs assertion, recommandation implicite, sarcasme, bruit d'annotation).
G	Tableau final : qualité, robustesse, temps d'entraînement, latence d'inférence par exemple sur CPU, taille du modèle ; matrice de confusion du modèle retenu.

QUESTIONS DU COMPTE-RENDU

Q1. Distribution des labels dans train, val et test, globalement et par type de sujet (long-standing / entity / event). Scores du classifieur trivial « toujours Expression ». Quelle métrique retenez-vous, et pourquoi ?

Q2. Raccourcis (Partie A) : quels indices superficiels sont corrélés aux labels ? Que valent vos classifieurs à une seule règle ? Qu'en concluez-vous sur la validité de vos scores ?

Q3. Quels choix de prétraitement avez-vous faits par famille de modèles ? Lesquels détruisent des indices utiles (ponctuation, mots interrogatifs, emojis) ? Chiffres à l'appui (ablation).

Q4. Zero-shot (B1) : score obtenu et sensibilité à la formulation des hypothèses. Pourquoi un modèle NLI peut-il classer sans exemple d'entraînement ? Quel rôle joue l'attention entre prémisse et hypothèse ?

Q5. Modèle de sentiment B2 sur la tâche auxiliaire : ses scores sont-ils anormalement élevés ? Expliquez avec la contamination.

Q6. Déséquilibre : comparez pondération, sur-échantillonnage, seuils par classe et focal loss (tableau, F1 par classe rare). Pourquoi le sur-échantillonnage doit-il être fait après la séparation train / val ?

Q7. C1 vs C2 vs C3 (et C4) : résultats. Les poids d'attention se concentrent-ils sur la ponctuation, les mots interrogatifs et les verbes d'obligation ? Effet de l'encodage positionnel ?

Q8. PLM gelé (D) vs fine-tuné (E1) : gain et coût (temps, paramètres entraînés). aubmindlab/bert-base-arabertv02-twitter vs UBC-NLP/MARBERTv2 : lequel, et pourquoi ?

Q9. Multi-tâche (E2) : l'ajout du sentiment améliore-t-il la tâche principale ? Effet de λ. Pourquoi une tâche auxiliaire peut-elle aider… ou nuire ?

Q10. Décalage de prior (F1) : comparez la distribution des labels de val et de test. Écart entre le seuil (ou la règle de décision) choisi sur val et l'optimum a posteriori sur le test. Que mettriez-vous en place en production (recalibration, monitoring) ?

Q11. Type de sujet non vu (F2) : chute mesurée. F1 des classes Request et Recommendation : combien d'exemples faudrait-il annoter pour les rendre fiables ?

Q12. Analyse d'erreurs (F6) : catégories dominantes, part du bruit d'annotation. Quel modèle mettriez-vous en production, et pourquoi (qualité, robustesse, coût, latence — chiffres à l'appui) ?

Pour tout ce qui n'est pas précisé ici (code de départ, classe MultiTask, format du compte-rendu), suivez le TP2.

Groupe 14

Mouad & Farouk

Binôme

Arabe dialectal

Identification du dialecte arabe au niveau du pays

Prédire le **pays** (21 pays arabes) d'origine d'un tweet en arabe dialectal. Tâche auxiliaire : la **province** (100 provinces).

DONNÉES

Jeu de données	NADI 2021, sous-tâches 1.2 (pays) et 2.2 (province), arabe dialectal.
Lien	github.com/UBC-NLP/nadi — **formulaire d'inscription** pour le téléchargement : à remplir dès la première séance.
Taille	21 000 train · 5 000 dev. Les labels du test ne sont pas publiés.
Labels	Attribués d'après la localisation des utilisateurs.
Plan B	Si l'accès tarde : IADD (135 804 textes, 9 pays, colonne DataSource) pour l'entraînement, et le test de QADI (`testset/QADI_test.txt`, 18 pays + MSA) comme test hors domaine. Auditez alors le croisement pays × DataSource.

> **Métriques : macro-F1** sur les pays (principale) ; macro-F1 sur les provinces.

POINTS D'ATTENTION

- 21 classes proches (dialectes voisins du Golfe, du Levant, du Maghreb).
- Labels bruités : un utilisateur peut écrire en MSA ou dans un autre dialecte.

Référence à citer : Abdul-Mageed et al., NADI 2021 — https://arxiv.org/abs/2103.08466

CONSIGNES, PARTIE PAR PARTIE

Protocole	dev = test scellé (labels du test non publiés) ; val = 10 % stratifié du train. Toutes les décisions se prennent sur val ; le test reste scellé jusqu'à la Partie F. Toute transformation apprise est ajustée sur le train uniquement. Journal `results/results.csv`.
4.1 Audit	Part de tweets sans marqueur dialectal (MSA) ; URL, mentions, emojis ; doublons. Doublons exacts et après normalisation (dans train, et entre train et test) ; doublons aux labels contradictoires : politique justifiée.
A	Distribution des labels, globalement et par pays et région (Maghreb, vallée du Nil, Levant, Golfe). Classifieur trivial « classe majoritaire ». Baseline TF-IDF (mots 1–2 + caractères 2–5) + régression logistique `class_weight="balanced"`, seuil(s) choisi(s) sur val. Raccourcis : règle « mot marqueur ⇒ pays » (ex. ديال ⇒ Maroc, عاع ⇒ Algérie) ; baseline TF-IDF caractères 1–5 seule.
B	B1 : NLI zero-shot (`MoritzLaurer/mDeBERTa-v3-base-xnli-multilingual-nli-2mil7`) avec « Ce tweet est écrit en dialecte marocain »… (une hypothèse par pays) ; au moins 3 formulations (arabe, français, anglais), score seuillé sur val. B2 : `CAMeL-Lab/bert-base-arabic-camelbert-mix-did-madar-corpus26` : regroupez ses villes en pays.
C	Vocabulaire construit sur train (fréquence ≥ 2), taux d'OOV sur val et test ; embeddings aléatoires, AraVec Twitter (figé puis dégelé). C1 BiLSTM, C2 BiLSTM + attention (implémentée par vous), C3 mini-encodeur Transformer (2 couches, d_model 128, 4 têtes ; ablation sans encodage positionnel), C4 char-CNN. Déséquilibre sur le meilleur modèle : perte pondérée, sur-échantillonnage (train uniquement), seuil optimisé. C4 char-CNN obligatoire : les marqueurs dialectaux sont au niveau des caractères.
D	D1 : `UBC-NLP/MARBERTv2` gelé, [CLS] vs moyenne des tokens → régression logistique. D2 : états de tous les tokens → tête BiLSTM + attention de C2 ; visualisez l'attention sur 5 exemples.
E	E1 : `UBC-NLP/MARBERTv2` et `CAMeL-Lab/bert-base-arabic-camelbert-da` fine-tunés ; perte pondérée, seuil choisi sur val. E2 : tête pays (21) + tête province (100), λ choisi sur val ; option : tête région. Départ : lr 2e-5, batch 32, 3 à 5 époques, warmup 10 %, early stopping sur val, 3 graines.

F	F1 : distribution des pays dans val et dans dev ; distribution des prédictions. F2 : test hors domaine : QADI (`testset/QADI_test.txt`) pour les pays communs ; F1 du Maroc. F3 : scores sur les tweets avec / sans mot marqueur. F4 : supprimez les mots marqueurs des tweets bien classés ; mesurez la chute. F5 : 3 graines, IC à 95 % par bootstrap (1 000), McNemar entre vos deux meilleurs modèles. F6 : 30 erreurs classées (MSA sans dialecte, dialecte voisin, emprunt, code-switching, bruit de label).
G	Tableau final : qualité, robustesse, temps d'entraînement, latence d'inférence par exemple sur CPU, taille du modèle ; matrice de confusion du modèle retenu.

QUESTIONS DU COMPTE-RENDU

Q1. Distribution des labels dans train, val et test, globalement et par pays et région (Maghreb, vallée du Nil, Levant, Golfe). Scores du classifieur trivial « classe majoritaire ». Quelle métrique retenez-vous, et pourquoi ?

Q2. Raccourcis (Partie A) : quels indices superficiels sont corrélés aux labels ? Que valent vos classifieurs à une seule règle ? Qu'en concluez-vous sur la validité de vos scores ?

Q3. Quels choix de prétraitement avez-vous faits par famille de modèles ? Lesquels détruisent des indices utiles (lettres répétées, emojis, mots dialectaux) ? Chiffres à l'appui (ablation).

Q4. Zero-shot (B1) : score obtenu et sensibilité à la formulation des hypothèses. Pourquoi un modèle NLI peut-il classer sans exemple d'entraînement ? Quel rôle joue l'attention entre prémisse et hypothèse ?

Q5. Le modèle MADAR (B2) transfère-t-il vers NADI ? Quelles régions sont confondues ?

Q6. Déséquilibre : comparez pondération de la perte, sur-échantillonnage et optimisation du seuil (tableau). Pourquoi le sur-échantillonnage doit-il être fait après la séparation train / val ?

Q7. C1 vs C2 vs C3 (et C4) : résultats. Les poids d'attention se concentrent-ils sur les mots marqueurs et les préfixes dialectaux ? Effet de l'encodage positionnel ?

Q8. PLM gelé (D) vs fine-tuné (E1) : gain et coût (temps, paramètres entraînés). UBC-NLP/MARBERTv2 vs CAMeL-Lab/bert-base-arabic-camelbert-da : lequel, et pourquoi ?

Q9. Multi-tâche (E2) : la tête province améliore-t-il la tâche principale ? Effet de λ. Pourquoi une tâche auxiliaire peut-elle aider… ou nuire ?

Q10. Décalage de prior (F1) : comparez la distribution des labels de val et de test. Écart entre le seuil (ou la règle de décision) choisi sur val et l'optimum a posteriori sur le test. Que mettriez-vous en place en production (recalibration, monitoring) ?

Q11. Erreurs sur les tweets marocains : MSA, dialecte voisin ou bruit de label ? 30 exemples classés. Comment évalueriez-vous honnêtement ce modèle avant un déploiement sur des tweets marocains ?

Q12. Analyse d'erreurs (F6) : catégories dominantes, part du bruit d'annotation. Quel modèle mettriez-vous en production, et pourquoi (qualité, robustesse, coût, latence — chiffres à l'appui) ?

Pour tout ce qui n'est pas précisé ici (code de départ, classe MultiTask, format du compte-rendu), suivez le TP2.